



ugr | Universidad
de **Granada**

TRABAJO FIN DE GRADO
INGENIERÍA EN INFORMÁTICA

Seguimiento Activo de Personas con dron Parrot Bebop2

Integración en ROS

Autor

José Javier Alonso Ramos

Directores

Francisco Barranco Expósito
Eduardo Ros Vidal



ESCUELA TÉCNICA SUPERIOR DE INGENIERÍAS INFORMÁTICA Y DE
TELECOMUNICACIÓN

—
Granada, Julio de 2020

Seguimiento Activo de Personas con dron Parrot Bebop2: Integración en ROS

José Javier Alonso Ramos

Palabras clave: parrot, bebop, bebop2, autonomy, autonomía, dron, drone, UAV, track, tracking, YOLO, YOLOv3, python, python2, python2.7, Deep, SORT, Deep-SORT, CNN, convolucionar, convolutional, neural, neuronal, network, red, ROS, rospy, opencv, opencv2, detection, detección, fly

Resumen

Este proyecto de fin de grado presenta el desarrollo de un sistema de video vigilancia activo y un estudio de la eficacia y la eficiencia del mismo. Como elemento activo se utiliza el dron Parrot Bebop 2 que hace la función de cámara móvil. Todo el trabajo se implementa sobre el framework ROS (Robot Operating System)

El objetivo principal es la automatización de movimiento del dron dotándolo de visión por computador e inteligencia artificial. Se implementa un comportamiento reactivo que obtiene como input el vídeo proporcionada por la cámara de a bordo. A esta entrada se le realiza, previamente, detección y seguimiento de personas.

Explicaremos las funcionalidades de ROS, el controlador del dron en cuestión (Bebop Autonomy) y el la implementación del comportamiento reactivo.

Por último mostraremos los resultados obtenidos durante las pruebas del sistema.

El proyecto será liberado, contribuyendo así a la comunidad de software libre. El código abierto en el campo de la robótica es relativamente escaso, por lo tanto se espera que esta contribución resulte útil para cualquier investigador o desarrollador.

Active Person Tracking using Parrot Bebop2 drone: Running in ROS

José Javier Alonso Ramos

Keywords: parrot, bebop, bebop2, autonomy, autonomía, dron, drone, UAV, track, tracking, YOLO, YOLOv3, python, python2, python2.7, CNN, Deep, SORT, Deep-SORT, CNN, convolucional, convolutional, neural, neuronal, network, red, ROS, rospy, opencv, opencv2, detection, detección, fly

Abstract

This Bachelor thesis presents the development of an active video surveillance system and a study of its effectiveness and efficiency. Parrot Bebop 2 drone is used as a system's active element which works as a mobile camera. The entire project has been implemented in ROS (Robot Operating System).

The main objective is to automate the drone's movement by providing it with computer vision and artificial intelligence. A reactive behavior is implemented that takes as input the video provided by the on-board camera. At this entrance, people are previously detected and tracked.

ROS functionalities will be explained as well as the drone driver (Bebop Autonomy) and the code that implements the reactive behavior.

The results of testing the project will be shown at the end.

The project will be released under a free software license, thereby contributing to the open source community. Open source in the field of robotics is relatively scarce, therefore this contribution is expected to be useful for any researcher or developer.

Yo, José Javier Alonso Ramos, alumno de la titulación INGENIERÍA INFORMÁTICA de la Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada, con DNI *, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: José Javier Alonso Ramos

Granada a 01 de junio de 2020.

*

D. **Francisco Barranco Expósito**, Profesor del Área de Ingeniería Informática del Departamento Arquitectura y Tecnología de Computadores de la Universidad de Granada.

D. **Eduardo Ros Vidal**, Profesor del Área de Ingeniería Informática del Departamento Arquitectura y Tecnología de Computadores de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado *Seguimiento Activo de Personas con dron Parrot Bebop2, Integración en ROS*, ha sido realizado bajo su supervisión por **José Javier Alonso Ramos**, y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a 15 de junio de 2020.

Los directores:

Francisco Barranco Expósito Eduardo Ros Vidal

Agradecimientos

A mi padre, que ha sido un gran colaborador en el proyecto, siempre dispuesto a realizar las pruebas de vuelo conmigo y a obligarme a dar lo mejor de mí mismo.

A mi madre, siempre entregada a su familia, dispuesta a escuchar tanto penurias como alegrías y capaz como nadie de diluir las primeras y ensalzar las segundas.

A mi hermana, que siempre supone un apoyo incondicional y cada día muestra interés en mis progresos tanto académicos como personales.

A mi hermano, que como mi padre, siempre ha estado dispuesto a realizar las pruebas del proyecto conmigo, y que ha vivido los avances en el mismo con la misma cercanía y alegría que yo.

Gracias también a mi familia en Madrid, que a pesar de la distancia que nos separa, me han hecho llegar todo su cariño y apoyo.

A mi tía Araceli, que se alegra como la que más por verme finalizar esta etapa y verme cumplir un sueño.

A mi primo Pedro, que siempre le entusiasman mis inventos caseros y grandes proyectos y cuya pasión por la ciencia nos une.

A mi primo Samuel, que siempre se preocupa de la felicidad de *"sus primos de Granada"* y que tiene un corazón enorme.

Y por supuesto, a mi abuela, que nos une a todos como nadie más podría hacerlo, y que siempre está pendiente y feliz de mis avances.

Por supuesto, dar las gracias a mis dos tutores, Eduardo y Francisco, por confiar en mí y darme la oportunidad de desarrollar este proyecto. En especial dar las gracias de nuevo a Fran y a su compañero Juan Ignacio, por su ayuda y plena disposición durante todo el proceso de desarrollo.

Por último, pero no menos importante, tengo que agradecer a todos mis amigos el conseguir sacarme una sonrisa en momentos de frustración, el conseguir que me despeje y cambiar el enfoque de la situación. Gracias a todos por apoyarme y hacerme feliz.

A todos ellos, que en todo momento me han apoyado y se han preocupado por mis avances y mi felicidad, gracias.

Declaración de autoría y originalidad del TFG

Yo, José Javier Alonso Ramos, con DNI *, declaro que el presente documento ha sido realizado por mí y se basa en mi propio trabajo, a menos que se indique lo contrario. No se ha utilizado el trabajo de ninguna otra persona sin el debido reconocimiento. Todas las referencias han sido citadas y todas las fuentes de información y conjuntos de datos han sido específicamente reconocidos.

Fdo: José Javier Alonso Ramos

Granada a 5 de julio de 2020.

Índice

1. Introducción	13
1.1. Motivación	14
1.2. Objetivos	15
1.3. Estado del Arte	16
2. Gestión del Proyecto	18
2.1. Metodología de Desarrollo	18
2.2. Planificación	18
2.3. Hitos	20
2.4. Presupuesto	22
2.4.1. Recursos Hardware	22
2.4.2. Recursos Software	22
2.4.3. Recursos Humanos	23
2.4.4. Coste Total	23
3. Entorno Operacional	24
3.1. Ubuntu 16.04	24
3.2. Robotic Operating System	24
3.2.1. Conceptos	25
3.3. Driver <i>bebop_autonomy</i>	28
3.3.1. Comandos ROS	30
3.4. Bebop 2	31
3.4.1. Especificaciones	31
3.5. Ordenador	33
4. Diseño	34
5. Implementación	36
5.1. Visión por Computador	36
5.1.1. Captación de imágenes del dron	36
5.1.2. Captación de imágenes de la webcam	37
5.1.3. Lectura de archivo de vídeo almacenado	37
5.1.4. Escritura de vídeo	38
5.1.5. Tracker - DeepSORT	38
5.1.6. Detector - YOLOv3	39
5.2. Comportamiento del Dron	40
5.2.1. Pilotaje Manual	40
5.2.2. Pilotaje Automático	41
5.2.3. Opciones Menú Principal	42

6. Problemas durante el desarrollo	43
6.1. Restricciones Harware	43
6.2. Restricciones Software	43
6.3. Restricciones Sanitarias	43
6.4. COVID-19	44
6.5. Problemas Técnicos	44
6.5.1. Virtualización	44
6.5.2. Equipo de Trabajo	45
6.5.3. Límite de Distancia de Conexión	46
6.5.4. Python y DeepSORT	47
6.5.5. Instalación de ROS2 junto a ROS Kinetic	47
6.5.6. Demo práctica del repositorio de <i>Qidian213</i> poco eficiente	48
7. Experimentación	50
7.1. Pruebas del Detector	51
7.1.1. Oclusión	51
7.2. Eficiencia del tracker DeepSORT en MOT Challenge	55
7.2.1. MOT17_12	55
7.3. Comparación: Intervalo 1	56
7.4. Comparación de Intervalos Superiores a 1	61
7.5. Intervalo: 2 fotogramas	61
7.6. Intervalo: 3 fotogramas	65
7.6.1. Consistencia del Tracker	69
7.7. Pruebas con el Dron	72
7.7.1. Vuelo con app	72
7.7.2. Ejecución en Equipo Portatil	75
7.7.3. Vuelo automático	76
7.7.4. Otros experimentos para evaluar Características No Funcionales de Calidad	83
8. Conclusiones y Futuras Mejoras	85

Índice de figuras

1.	Dron de reparto de Amazon	16
3.	2015 - Uso de drones en la industria	17
5.	Captura del tablero de Trello	18
6.	Tabla Gantt de Planificación	19
8.	Esquema de flujo de información mediante Tópics en ROS . .	25
10.	Estructura de mensaje Image	26
12.	Estructura de mensaje Twist	27
14.	Esquema de desplazamiento de Bebop 2 con velocidades po- sitivas	28
16.	Organización de directorios de bebop_autonomy	29
18.	Interfaz de conexión Bebop2 - ROS - PC para la obtención de imagen del dron.	30
20.	Parrot Bebop 2	31
22.	Esquema de nodos ROS en la aplicación	34
24.	Esquema de comunicación entre los módulos de la aplicación	35
25.	Ejemplo de archivo txt generado	38
26.	Rendimiento de YOLOv3 frente a otros algoritmos de detección	39
28.	Menú principal + Menú de pilotaje manual	40
29.	Diálogo de selección de objetivo	41
30.	La imagen muestra la evolución de la cantidad de <i>fps</i> y tracks detectados a lo largo de los frames obtenidos. Como vemos, los <i>fps</i> rondan los 0.7. Analizaremos esta gráfica en mayor profundidad más adelante en el apartado de experimentación.	45
31.	Detección ineficiente en demo.py	48
33.	MOT17_12 imagen:0 426x240	51
34.	MOT17_12 imagen:1 854x480	51
35.	MOT17_12 imagen:2 1920x1080	52
36.	<i>fps</i> frente a la resolución de la imagen	53
38.	Número de tracks detectados por frame	56
39.	Tiempo de procesamiento requerido por frame	57
40.	Número de tracks detectados por frame	58
41.	Tiempo de procesamiento requerido por frame	59
42.	Número de tracks detectados por frame	61
43.	Tiempo de procesamiento requerido por frame	62
44.	Número de tracks detectados. Intervalo:2 Periodo: 1	63
45.	Número de tracks detectados. Intervalo:1 Periodo: 2	63
46.	Número de tracks detectados por frame	65
47.	Tiempo de procesamiento requerido por frame	66
48.	MOT17_05 secuencia:0	69
49.	MOT17_05 secuencia:1	69
50.	MOT17_05 secuencia:2	70
51.	MOT17_05 secuencia:3	70

52.	MOT17_05 secuencia:4	71
53.	Interfaz HUD (Head-Up Display) del modo pilotaje manual de la aplicación Free Flight Pro	72
54.	Interfaz HUD (Head-Up Display) del modo pilotaje automático de la aplicación Free Flight Pro	73
55.	Dron siguiendo al objetivo de manera activa	74
56.	Evolución de <i>fps</i> y número de tracks a lo largo de los frames .	75
57.	Estado del equipo portátil durante la ejecución de la aplicación	75
58.	<i>fps</i> en modo manual	76
59.	<i>fps</i> en modo automático	76
60.	Inicio del sistema	77
61.	Selección de ID en cámara fija	78
62.	Salida de escena	79
63.	Despegue automático	79
64.	Selección de objetivo en vídeo del dron	80
65.	Detección a contra luz - Bebop	80
66.	Detección a contra luz - Servidor	81
67.	Detección en alto contraste - Bebop	81
68.	Detección en alto contraste - Servidor	82
69.	Evolución en vídeo Bebop	83
70.	Evolución en vídeo Cámara fija	83

Índice de cuadros

1.	Tabla de costes hardware	22
2.	Tabla de costes software	22
3.	Tabla de costes totales.	23
4.	Tabla sintetizada de problemas, planes de contingencia y soluciones finales	49
5.	FPS frente a Resolución	53
7.	Número de Trazados frente a Resolución	54
9.	Resultados de ejecución en MOT17_12	60
11.	Comparativa Intervalo vs Periodo	62
12.	Resultados de ejecución en MOT17_12	64
14.	Comparativa Intervalo vs Periodo	66
15.	Resultados de ejecución en MOT17_12	67
17.	Comparativa de ejecuciones con distintos intervalos de lectura	68

1. Introducción

Hoy en día, empresas, instituciones públicas y particulares invierten cada vez más en sistemas de videovigilancia para llevar un control riguroso de ciertas zonas, infraestructuras o viviendas y asegurar así su integridad. Muchas de estas áreas son extremadamente sensibles ante posibles “atacantes” y la importancia de su conservación y buen funcionamiento es vital tanto para la entidad contratante como para la sociedad. Nos referiremos a estas áreas sensibles como infraestructuras críticas, término definido por la Directiva Europea el 8 de diciembre de 2008 [1] como:

“El elemento, sistema o parte de este situado en los Estados miembros que es esencial para el mantenimiento de funciones sociales vitales, la salud, la integridad física, la seguridad, y el bienestar social y económico de la población y cuya perturbación o destrucción afectaría gravemente a un Estado miembro al no poder mantener esas funciones”

Ejemplos de infraestructuras críticas serían: Administración (servicios básicos, instalaciones, redes de información, y principales activos y monumentos del patrimonio nacional); Instalaciones del Espacio; Industria Química y Nuclear (producción, almacenamiento y transporte de mercancías peligrosas, materiales químicos, biológicos, radiológicos, etc.); Agua (embalses, almacenamiento, tratamiento y redes); Centrales y Redes de energía (producción y distribución); Tecnologías de la Información y las Comunicaciones (TIC); Salud (sector e infraestructura sanitaria); Transportes (aeropuertos, puertos, instalaciones intermodales, ferrocarriles y redes de transporte público, sistemas de control del tráfico, etc.); Alimentación (producción, almacenamiento y distribución); y Sistema Financiero y Tributario (entidades bancarias, información, valores e inversiones).

La videovigilancia de estas áreas es a lo que va dedicado este proyecto; más concretamente a la videovigilancia activa e inteligente incorporando un elemento móvil (dron) y dotando al sistema de visión por computador.

En los últimos años se han obtenido grandes avances en el campo de visión por computador gracias al desarrollo de avanzadas y complejas técnicas (algoritmos) de Inteligencia Artificial y aprendizaje profundo que permiten una detección precisa de distintas figuras en escena e, incluso, un seguimiento (*tracking*) consistente de múltiples objetos (MOT). Esta situación nos crea un marco contextual ideal para desarrollar sistemas inteligentes de videovigilancia.

Como elemento activo del sistema contamos con un dron Parrot Bebop 2 el cual es la herramienta ideal para desarrollar este papel, al menos, en un ámbito académico y/o de investigación, ya que es una plataforma que nos aporta total libertad para su configuración. Nos permite modificar su firmware de una manera sencilla (dispone de un puerto USB para conectarnos directamente a la placa controladora) y, además, gracias a bibliotecas disponibles en Python y C++ y a la implementación de los drivers de vuelo en un paquete (*Bebop Autonomy* [2]) del framework ROS (*Robot Operating*

System [3]) es relativamente sencillo desarrollar software de visión y pilotaje del aparato.

Dentro del mundo de los drones que podemos obtener de manera particular (sin ser una empresa o institución), se trata de una muy buena opción por todo lo nombrado anteriormente y por su precio, que es sustancialmente menor que otras marcas y modelos.

1.1. Motivación

Como ya hemos dicho, este trabajo de fin de grado está enfocado al sector de la *videovigilancia*, más específicamente a la videovigilancia activa de infraestructuras críticas, es decir, utilizar uno o más drones como sistema de vigilancia de una determinada zona o edificio que, por norma general, se encontrará aislado, será poco accesible y, por tanto, será poco frecuentada por personas. Además su seguridad, integridad y buen funcionamiento son de muy alta importancia.

El hecho de que se encuentre aislada y poco accesible es lo que hace muy interesante la incorporación de un sistema inteligente para vigilar el lugar. Esto es porque, actualmente, es personal cualificado que se encuentran físicamente allí, el que se encarga de la vigilancia bien mirando pantallas o monitores que muestran la imagen de cámaras estáticas, o bien patrullando la zona. Estas dos tareas asociadas a unos cambios de guardia poco frecuentes pueden generar fatiga en los trabajadores y dar lugar tanto a falsos positivos como a falsos negativos.

En el peor de los casos (Falso Negativo: No dar la alarma ante una emergencia real) pondremos en riesgo la integridad de la zona, y deberemos asumir las repercusiones que puede tener para la sociedad (por ejemplo la caída de una central eléctrica puede suponer que una parte de la población se quede sin luz), además de los costes de arreglar los daños sufridos y/o ocasionados.

El caso más leve (Falso Positivo: dar la alarma ante una situación de no peligro) supondrá el despliegue de un equipo policial hasta la zona y acarrear dichos costes. Si se dan varias falsas alarmas, el sistema de vigilancia se considerará poco efectivo y perderá credibilidad de manera que las autoridades pueden no considerar relevante futuras emergencias.

Todo esto junto con el elevado coste periódico que supone mantener un personal especializado para la vigilancia, nos hace pensar que sería muy útil un sistema inteligente que nos asegure una amplia probabilidad de acierto a la hora de detectar intrusos. Supondría un ahorro de personal, y su efectividad sería constante ya que no se vería afectado por ningún tipo de fatiga. De esta manera podríamos prepararnos ante posibles falsos positivos y buscar un suplemento (si fuera necesario), para los falsos negativos. Además, al incorporar un elemento activo como es el dron, nos abre la posibilidad de disminuir el número de cámaras fijas en el entorno y seguir la pista de un posible intruso hasta zonas más inaccesibles para informar de su posición en tiempo real.

1.2. Objetivos

En este proyecto se realiza un estudio sobre la eficacia que presenta el dron Parrot Bebop 2 como elemento de un sistema de videovigilancia activo. Durante el desarrollo del trabajo se pretenden cumplir los siguientes objetivos:

- Estudiar el estado del arte de los drones y los sistemas de videovigilancia.
- Aprender las funcionalidades y herramientas de las que dispone el framework ROS que nos permiten abstraernos de la interconexión y comunicación de nodos heterogéneos.
- Acercarnos al mundo de la Inteligencia Artificial utilizando un detector y módulo de seguimiento (*tracker*) basados en *deep learning*: YOLOv3 [4] y DeepSORT [5] respectivamente.
- Implementar un sistema de control manual para pilotar el dron.
- Implementar un comportamiento reactivo que permita al dron perseguir un determinado objetivo.
- Dar un enfoque más genérico al proyecto de manera que pueda aplicarse a más campos de trabajo y no sólo a la videovigilancia.
- Desarrollar software libre en forma de un paquete ROS alojado en GitHub.
- Aprender nuevos programas de planificación y comunicación como *Trello* y *Slack*.

1.3. Estado del Arte

Cada vez son más los sectores en los que el uso de drones se ha estandarizado y es que es una tecnología muy versátil que ha llegado para quedarse.

Uno de los campos en el que es más fácil ver su amplio uso es en la industria del cine o filmografía más *amateur* [6] donde son muy utilizados para tomar amplios planos de un paisaje, grandes planos picados o para grabar persecuciones.

Actualmente se está intentando implantar su uso en empresas de mensajería y paquetería como UPS [7], que ha desarrollado un sistema que aprovecha la sinergia del reparto simultáneo con camiones para paquetes pesados y con drones para paquetes ligeros. El gigante de comercio electrónico, Amazon, también está invirtiendo en su propia flota de drones y, de hecho, ya cuenta con varios modelos de prueba [8]. Hasta Correos, en España, ha realizado ya las primeras pruebas de reparto en zonas de difícil acceso mediante drones [9]. La transición hacia este nuevo método de reparto será lenta debido a la falta de legislación y a los grandes cambios de infraestructura que requiere.

También se está estandarizando el uso de drones en el control de planes de urbanismo (como nos explica este artículo de la Universidad de Córdoba [10]), en la vigilancia del tráfico (informe de la DGT [11]), como elemento de monitorización y optimización de plantaciones agrícolas (TFG presentado en la Universidad Politécnica de Valencia en 2017 [12]) y, recientemente, como sistemas de videovigilancia (artículo publicado por IEEE [13]), ya que permiten obtener un estado de la situación prácticamente en tiempo real y nos brindan la oportunidad de movernos con libertad para poder adecuarnos mejor a la situación.

Estos son tan sólo unos pocos usos de todos los que nos podemos encontrar en la actualidad. Para ver hasta 38 situaciones en las que usamos hoy en día los drones se recomienda echar un vistazo a este artículo de *CB INSIGHTS* [14] que ofrece una visión general del tema sin entrar mucho en detalle.



Figura 1: Dron de reparto de Amazon

Fuente: [8]

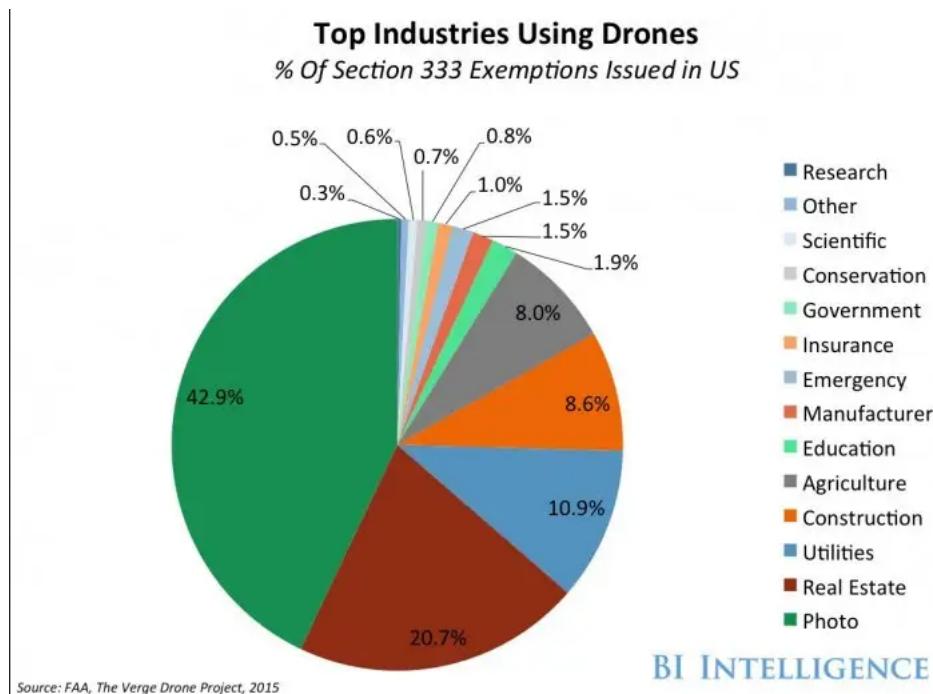


Figura 3: 2015 - Uso de drones en la industria

Gráfico extraído de Business Insider [15]

La figura 3 expuesta en el artículo [15] de *Business Insider* recoge los datos de la *Federal Aviation Administration - FAA* [16] de 2015 sobre el uso de los drones en las distintas industrias en Estados Unidos.

Como podemos ver, el mayor uso de drones (42.9 %) se da en la industria de la fotografía como hemos hablado antes. En segunda posición con aproximadamente la mitad de uso (20.7 %), aparece el sector relacionado con propiedades inmueble y planes de urbanismo. El tercer puesto lo ocupa el sector de servicios públicos y supone, aproximadamente, la mitad de uso respecto al segundo puesto (10.9 %). En el cuarto y quinto puesto aparecen los sectores de construcción y agricultura respectivamente (8.6 % y 8.0 %), siendo el uso en el sector de construcción ligeramente superior (0.6 % mayor). La participación de los drones en el resto de sectores vemos que es ínfima en comparación a los mencionados.

2. Gestión del Proyecto

2.1. Metodología de Desarrollo

Se ha utilizado la metodología de *Desarrollo de Prototipos* [17] en la que nos centramos en construir prototipos o versiones funcionales del proyecto de manera asidua para poder obtener una retroalimentación e ir refinando así el resultado final.

Esta metodología resulta muy útil cuando conocemos los objetivos generales que queremos alcanzar pero no identificamos con exactitud los requisitos de entrada, procesamiento o salida. También ofrece un mejor enfoque cuando estamos inseguros sobre la eficacia de algún algoritmo (como nos ocurre con DeepSORT), sobre la adaptabilidad de un sistema operativo o, en este caso, el framework ROS, o si no tenemos clara la forma de interacción humano-máquina (modo de pilotaje manual).

Por todos estos motivos nos ha parecido un modelo de desarrollo bastante adecuado que, además, nos permite saber si progresamos adecuadamente.

2.2. Planificación

Para organizar el proyecto se ha hecho uso de la plataforma *Trello* [18] conectada con la herramienta de comunicación en equipo *Slack* [19] de manera que tanto yo, como mis tutores hemos tenido acceso a la planificación y avances del trabajo. Además, también conectado al canal de Slack, se encuentra el repositorio del proyecto alojado en GitHub [20].

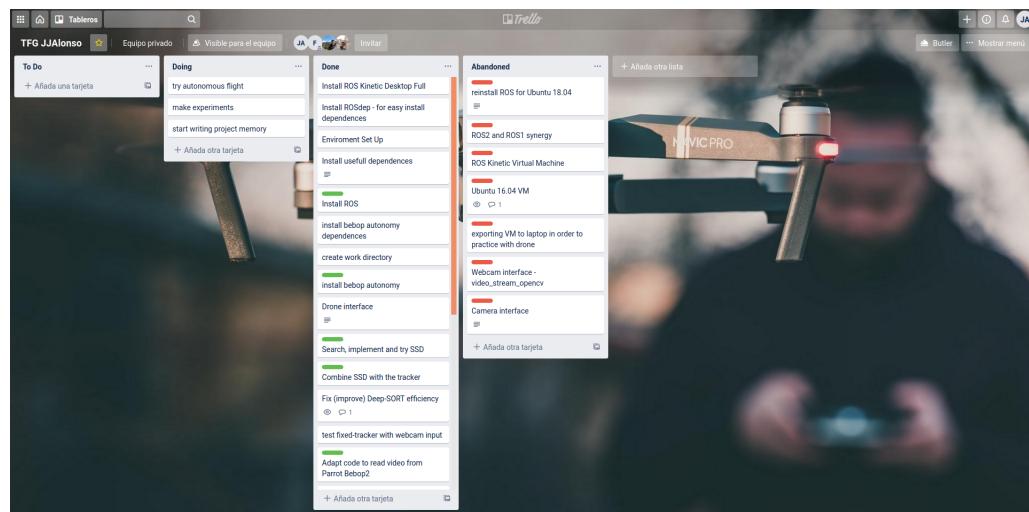


Figura 5: Captura del tablero de Trello

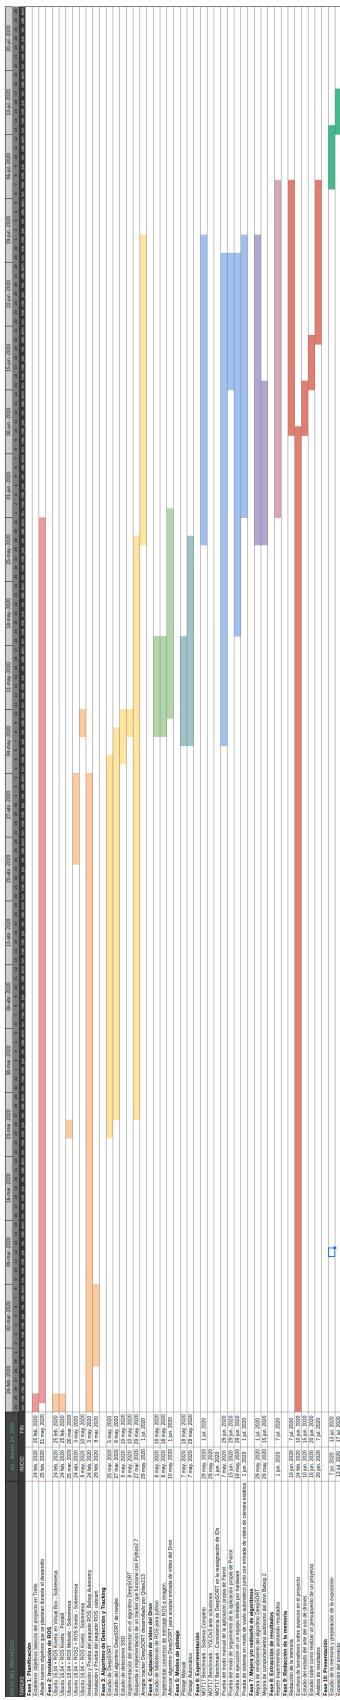


Figura 6: Tabla Gantt de Planificación
Ver con más detalle en carpeta MEGA [21]

El cuadro representa el tiempo real dedicado a cada tarea.

En general, el desempeño de cada tarea ha sobrepasado la duración estimada al inicio del proyecto. En especial, la instalación de la base sobre la que empezar a trabajar, es decir, la instalación del sistema operativo Ubuntu junto con el marco de desarrollo (*framework*) ROS. Esta tardanza en tener operativa la base del proyecto, se debe a que necesitamos Python2.7 para hacer funcionar nuestro código y debido a la ausencia de soporte para este lenguaje, surgieron distintas incompatibilidades (comentaremos esto más adelante en el apartado de problemas 6.4).

Otra tarea que se extendió en el tiempo mucho más de lo esperado, fue hallar un algoritmo de seguimiento (*tracking*), y fue debido al mismo motivo que antes. Estas dos situaciones hicieron que el proyecto avanzase muy lentamente, y generase un retraso notable en el cumplimiento de hitos 2.3.

El resto de tareas, aunque también tomaron algo más de tiempo que el previsto, fue algo que manteníamos dentro de nuestros márgenes.

2.3. Hitos

Los objetivos específicos han variado mucho a lo largo del desarrollo ya que se han ido planteando distintos enfoques hasta dar con el más indicado, sencillo y efectivo. Por ello los objetivos aquí definidos son los correspondientes con el desarrollo final. En un posterior apartado se explicarán las distintas maneras que se han estudiado para afrontar el proyecto y por qué finalmente se dejaron de lado.

1 Instalar Ubuntu 16.04

Es la distribución de linux en la que se encuentra disponible ROS Kinetic.

2 Instalar ROS Kinetic

Es la versión de ROS en la que funciona el driver Bebop Autonomy.

3 Instalar Bebop Autonomy

Es el driver que nos permitirá establecer conexión con el dron y comunicarnos con él.

4 Escoger algoritmo de seguimiento (*tracking*) de personas

Buscar un algoritmo de seguimiento (*tracking*) que funcione en nuestra instalación.

5 Crear una interfaz para leer imágenes del dron

Desarrollar una interfaz software que transforme los mensajes ROS en datos útiles que podamos utilizar para el desarrollo.

6 Desarrollar un control manual para el dron

Implementar un modo de vuelo manual para realizar una primera toma de contacto al enviar comandos de movimiento al dron. También nos permite tomar el control del aparato en caso de que haya algún problema.

7 Desarrollar un control autónomo para el dron

Desarrollar el objetivo principal del proyecto. Dotar al dron de un comportamiento reactivo para perseguir a un objetivo designado.

8 Implementar paquete ROS con el proyecto

Transformar el repositorio del proyecto en un paquete ROS de manera que se pueda usar mediante comandos del framework.

9 Crear launchfile para ejecutar el proyecto desde ROS

Crear un archivo ejecutable por ROS que lance automáticamente el driver del dron y el software del proyecto.

Estos objetivos podemos sintetizarlos en dos grandes grupos:

- Conseguir un sistema estable en el que llevar a cabo el desarrollo
Objetivos: 1,2,3
- Establecer una conexión dron-servidor, y programar el comportamiento del dron
Objetivos: 4,5,6,7,8,9

2.4. Presupuesto

2.4.1. Recursos Hardware

El presupuesto de este proyecto se ha calculado de la siguiente manera:

$$(D/V) * C$$

Donde:

- D es el número de meses que se ha utilizado el producto para el proyecto.
- V es la vida útil del producto en número de meses.
- C es el coste total del producto en euros.

Artículo	Coste (€)	Dedicación (meses)	Vida Útil (meses)	Coste Aplicable (€)
Bebop2	550	4	120	18.3
Ordenador de sobremesa	1200	4	60	80
Total				98.3

Cuadro 1: Tabla de costes hardware.

2.4.2. Recursos Software

Artículo	Coste (€)
Ubuntu 16.04	0.0
ROS	0.0
Visual Studio Code	0.0
Total	0.0

Cuadro 2: Tabla de costes software

2.4.3. Recursos Humanos

Este trabajo ha requerido, aproximadamente, 100 días de trabajo en los que se han invertido unas 4 horas diarias.

Suponiendo que un ingeniero informático recién graduado en España representa un coste de 2000 euros al mes teniendo una jornada laboral de 8 horas diarias (aproximadamente 12.5€/h), las 400 horas del proyecto serían valoradas en 5000€.

2.4.4. Coste Total

COSTE TOTAL	
Recursos Harware	98.3€
Recursos Software	0.0€
Recursos Humanos	5000€
Coste Total	5098.3€

Cuadro 3: Tabla de costes totales.

Si añadimos un 10 % referido a gastos de luz, recambio de piezas, nuevos componentes para el ordenador, etc. el coste total del proyecto ascendería a:

PRECIO TOTAL: 5608.13€

3. Entorno Operacional

Vamos a hablar de ROS (el framework utilizado), la versión de Ubuntu seleccionada, así como de los componentes hardware involucrados más destacables como es el ordenador que ha actuado como servidor y centro de cómputo y el dron Parrot Bebop 2.

En esta sección aprovecharé para hablar de los problemas con los que nos hemos topado ya que la gran mayoría de ellos se han dado durante la preparación de este escenario base sobre el que desarrollar el proyecto.

3.1. Ubuntu 16.04

El proyecto se ha desarrollado en esta distribución de Linux por dos decisivos motivos. El primero es que ROS ofrece una de sus versiones más robustas para esta distribución: ROS Kinetic. Esta versión de ROS tiene una gran comunidad de soporte y por tanto podemos encontrar gran cantidad de paquetes, bibliotecas y ayuda para casi cualquier problema que tengamos. El segundo motivo ha sido el que realmente a volcado la balanza hacia ROS Kinetic y no hacia cualquier otra versión, y es que el paquete que ofrece los drivers para controlar a nuestro dron se ha desarrollado en esta versión de ROS y es donde su funcionamiento está garantizado.

3.2. Robotic Operating System

Este framework libre, más conocido por su acrónimo ROS [3] [22], está orientado hacia el desarrollo de aplicaciones para robots. Nos brinda una gran colección de bibliotecas y herramientas que nos permiten desarrollar software complejo que garantice un comportamiento robusto en los robots.

ROS surge como la necesidad de estandarizar la manera de afrontar la programación del comportamiento de los robots. Hasta la tarea más trivial desde una perspectiva humana nos resultará compleja de diseñar e implantar en un robot en cuanto empecemos a tener en cuenta la enorme cantidad de factores y decisiones que entran en juego y que nosotros, como humanos, tomamos casi inconscientemente.

Por su filosofía de software libre, cualquiera puede contribuir en ROS creando paquetes que resuelvan problemas “*generales*” de manera que otra persona pueda usarlo para resolver otro problema más complejo e ir escalando en la dificultad. Así un laboratorio formado por expertos podría desarrollar un paquete dedicado a mapear interiores, otro equipo podría usar ese paquete para crear orto que permita desplazarse por el mapa y un tercero que implemente visión por computador para reconocer objetos mientras se mueve.

3.2.1. Conceptos

Hay una serie de conceptos básicos de ROS que es necesario definir para entender bien su funcionamiento:

- **Paquetes:** Son la unidad básica de organización de ROS. Un paquete puede contener nodos, una biblioteca independiente, un conjunto de datos, archivos de configuración, un software de terceros o cualquier otra cosa que constituya un módulo útil. El objetivo de estos paquetes es proporcionar esta funcionalidad útil de una manera fácil de consumir para que el software pueda reutilizarse fácilmente. La definición de un paquete de ROS perfecto es aquel que aporta suficiente funcionalidad para resultar útil pero que no pesa demasiado para resultar difícil de usar en otro proyecto.
- **Nodos:** Son los procesos de ROS que realizan computación, sensorización o algún tipo de acción. Los nodos pueden comunicarse entre sí por medio de *stream topics* o tópicos de transmisión, servidores RPC (Remote Procedural Call) o servidores de parámetros.
- **Temas(Topics):** Los *topics* son canales de comunicación etiquetados sobre los que los nodos pueden escribir y leer mensajes. Las publicaciones y suscripciones en los buffers son anónimas de manera que un nodo con el rol de “*publisher*” no sabe con qué otro nodo se está comunicando. Puede haber varios suscriptores y publicadores en un mismo buffer pero la comunicación siempre es unilateral. 8

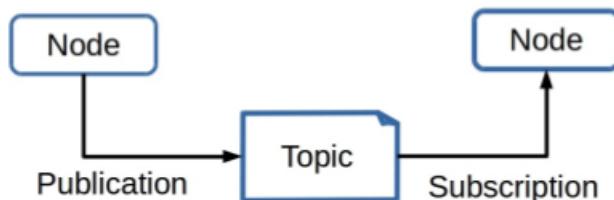


Figura 8: Esquema de flujo de información mediante Tópicos en ROS

Diagrama extraído del TFG de Valero Lavid [23]

- **Servidores RPC:** El paradigma de los *topics* es muy flexible pero la comunicación unidireccional puede llegar a ser un problema. Para las comunicaciones bidireccionales utilizamos los servidores RPC en los que un nodo proveedor ofrece un servicio al que un nodo cliente llama enviando un mensaje y esperando una respuesta.
- **Servidores de Parámetros:** Un servidor de parámetros es un diccionario compartido al que se puede acceder a través de las API de red.

Los nodos usan este servidor para almacenar y recuperar parámetros en tiempo de ejecución. Como no está diseñado para un alto rendimiento, se utiliza mejor para datos estáticos, no binarios, como los parámetros de configuración. Está destinado a ser visible globalmente para que las herramientas puedan inspeccionar fácilmente el estado de configuración del sistema y modificarlo si es necesario.

- **Mensajes:** Son las estructuras de datos con la que se comunican los nodos. Existen varios tipos pero los que utilizamos especialmente en el proyecto son *sensor-msgs/Image.msg* 10 y *geometry-msgs/Twist.msg* 12 que presentan la siguiente estructura:

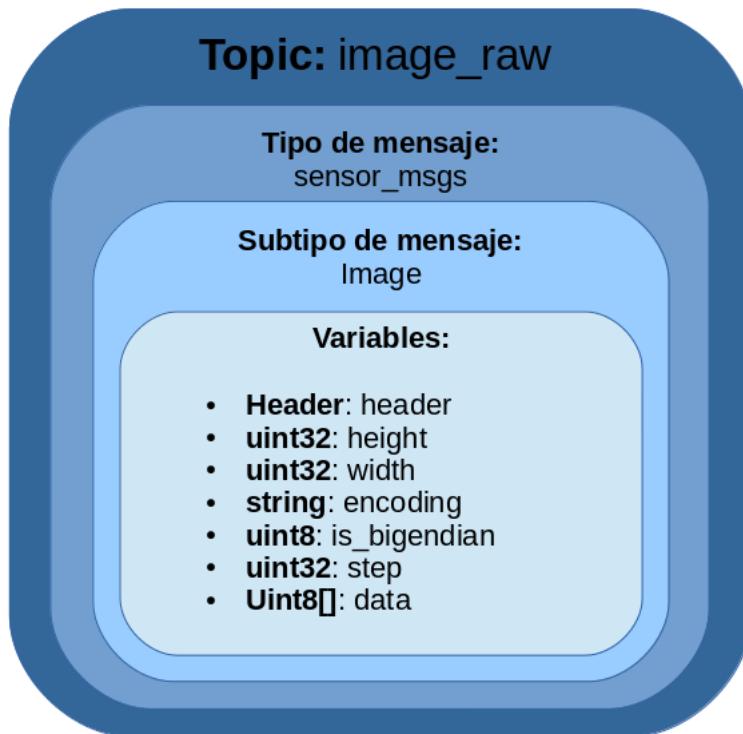


Figura 10: Estructura de mensaje Image

Información obtenida de la documentación de ROS [24]

Idea de diseño obtenida del TFG de Valero Lavid [23]

- **header** es otro tipo de mensaje ROS que contiene un identificador del frame asociado, un contador que indica su posición en la secuencia de imágenes y una marca de tiempo que indica en qué momento se ha captado la imagen.
- **height** y **width** hacen referencia a la resolución de la imagen (W x H píxeles)

- **encoding** es el formato en el que se representa internamente la imagen. Número de canales, su orden y significado de cada uno.
- **is_bigendian** es suficientemente autodescriptivo.
- **step** indica en bytes la longitud que hay entre el primer píxel de una fila de la imagen y el primer píxel de la siguiente fila. Dado que los canales de color y la resolución pueden variar, step es un atributo muy útil para recorrer las filas de una imagen.
- Por último **data** contiene la matriz que representa la imagen.



Figura 12: Estructura de mensaje Twist

Información obtenida de la documentación de ROS [25]

Idea de diseño obtenida del TFG de Valero Lavid [23]

Vector3 es un tipo de dato que consta de tres atributos de tipo float64 (x,y,z) para representar vectores en un espacio 3D. Para controlar el dron Bebop 2 debemos asignar valores a estos atributos en el dominio [0,1] siendo 0 la ausencia de velocidad y 1 la entrega de máxima potencia.



Figura 14: Esquema de desplazamiento de Bebop 2 con velocidades positivas

Imagen extraída del TFG de Valero Lavid [23]

- **Bolsas(Bags):** Se trata de un formato especial que permite al usuario la opción de guardar o reproducir mensajes de datos de ROS.
- **Comandos:** Son una serie de órdenes para navegar por el sistema de ficheros y modificar o mostrar tópicos y mensajes.

3.3. Driver *bebop_autonomy*

bebop_autonomy es un paquete de ROS que actúa como driver para los drones Bebop 1 y Bebop 2. Está basado en el SDK *ARDroneSDK3* oficial de Parrot. Este driver ha sido desarrollado por el *autonomy lab* en la universidad Simon Fraser por Mani Monajjemi además de otros colaboradores [26].

Al ejecutar el driver *bebop_autonomy* se crean una serie de Topics a los que nos podemos suscribir para recibir información como */bebop/image_raw* del que leemos las imágenes captadas por la cámara, o */bebop/states/common/CommonState/BatteryStateChanged* que nos informa de cambios en el estado de la batería.

También se crean Topics en los que debemos hacer publicaciones para controlar el dron como */bebop/cmd_vel* al que indicamos en qué dirección debe moverse o rotar y con qué velocidad, o */bebop/takeoff* y */bebop/land*

a los que debemos mandar un mensaje estandar vacío (tipo Empty) para hacer despegar o aterrizar al dron respectivamente. En el proyecto también se hace uso del topic `/bebop/reset` en el cual, mandando un mensaje tipo Empty, provocaremos la detención inmediata del dron (modo de emergencia). El topic `/bebop/record` nos sirve para iniciar o detener la grabación de lo que capta la cámara (se graba en la memoria a bordo del dron).

Para ejecutar el driver escribimos lo siguiente:

```
$ rosrun bebop_driver bebop_nodelet.launch
```

Este comando inicia los topics y prepara la comunicaciones con el dron. Si suponemos que a nuestro directorio de trabajo lo hemos llamado 'TFG' la organización de carpetas sobre la que se encuentran los drivers tendrá la siguiente forma:

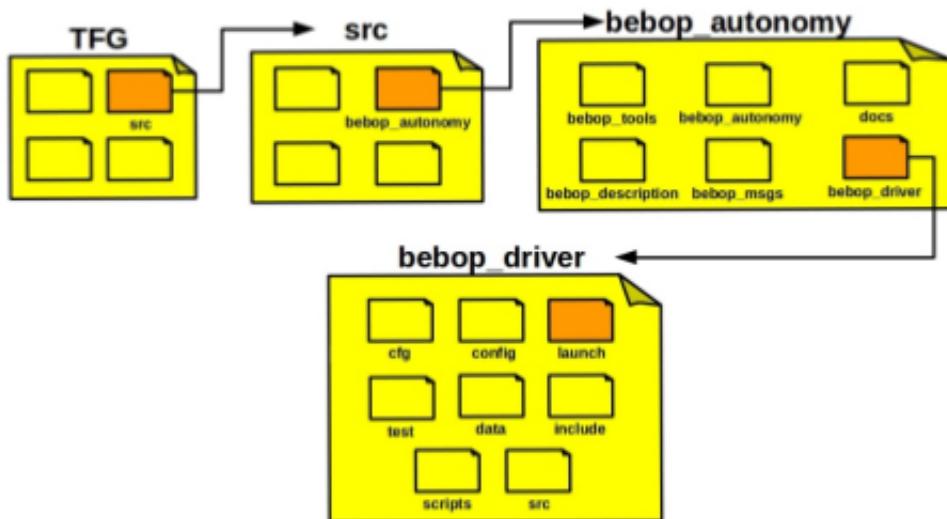


Figura 16: Organización de directorios de `bebop_autonomy`

Diagrama extraído del TFG de Valero Lavid [23]

Existe otro driver que a parte de iniciar los topics, se suscribe a uno de ellos (`/bebop/image_raw`) y abre una ventana por la que muestra la imagen que recibe. Para utilizar este driver tecleamos en la terminal lo siguiente:

```
$ rosrun bebop_tools bebop_nodelet_iv.launch
```

Este *launch file* es un buen primer contacto con `bebop_autonomy` ya que nos permite ver de manera más visual que la instalación, tanto de

ROS como del paquete de drivers, ha tenido éxito y que la interfaz de conexión con el dron funciona y recibimos imagen.

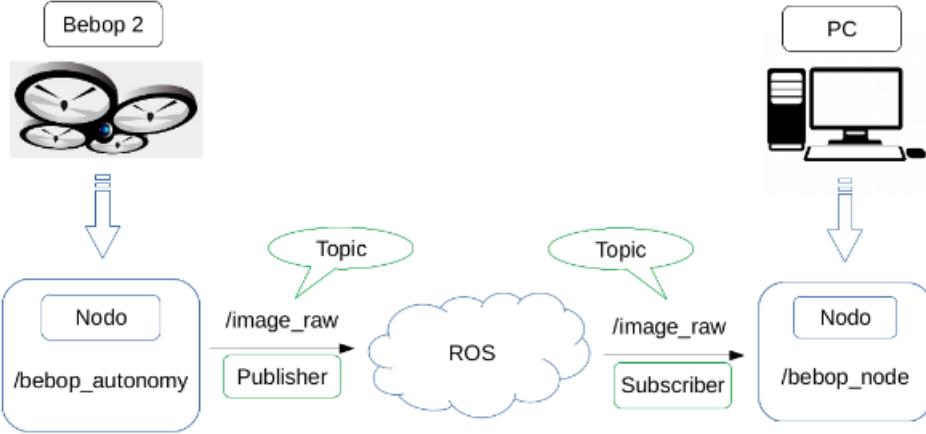


Figura 18: Interfaz de conexión Bebop2 - ROS - PC para la obtención de imagen del dron.

Diagrama extraído del TFG de Valero Lavid [23]

3.3.1. Comandos ROS

- **roscore:** Inicializa el núcleo de ROS y permite la comunicación entre nodos, servicios, parámetros, etc.
- **roscreate-pkg:** Con esta herramienta podemos crear paquetes ROS, pudiendo además especificar las dependencias de los mismos.
- **rospack:** Muestra información de un paquete.
- **rosstack:** Información de la “pila” que se deseé.
- **roscd:** Permite movernos dentro del directorio de trabajo.
- **rosls:** Muestra el contenido de la carpeta que indiquemos dentro del directorio de trabajo.
- **rosnode:** Muestra una lista los nodos en ejecución, información de un nodo o permite eliminar nodos de la ejecución.
- **rosdep:** Permite descargar dependencias de paquetes.
- **rostopic:** Herramienta útil para controlar Topics. Se puede obtener una lista de todos los Topics en ejecución, así como publicar mensajes en ellos, obtener información o leer los datos de dichos Topics.

- **rosservice:** Al igual que los Topics, se puede obtener una lista de los distintos servicios que se están ejecutando, información y utilizar dichos servicios para un fin.
- **rosmsg:** Obtiene la información de un tipo de mensaje.
- **rosrun:** Ejecuta un archivo ejecutable de un paquete específico.
- **roslaunch:** ROS permite ejecutar varios nodos a la vez. Mediante esta herramienta se puede ejecutar archivos con formato .launch, en estos archivos se puede configurar varios nodos para poder ejecutarlos a la vez facilitando al usuario el uso del sistema global de ROS.

3.4. Bebop 2



Figura 20: Parrot Bebop 2

Imagen de la página oficial de Parrot [27]

La imagen muestra el modelo de dron utilizado para desarrollar el proyecto y hacer las distintas pruebas y experimentos. Se trata de la segunda revisión del modelo Bebop (Bebop 2) de la marca Parrot [27].

3.4.1. Especificaciones

- **Imagen:** Cuenta con una cámara de **14.0 Megapíxeles** que permite hacer fotografías con una resolución de **3800 x 3188 píxeles** y grabar vídeo a **30 fotogramas por segundo** en **full HD** (1920 x 1080 píxeles). Además cuenta con **estabilización digital** en los tres ejes un ángulo de visión de **180º**. Estas resoluciones de imagen las obtenemos al grabar los datos en la memoria interna del propio dron, pero si

enviamos los datos a través de la interfaz wifi mediante la que nos conectamos, obtenemos una resolución de imagen de 856 x 480 píxeles. Esto se debe principalmente a que necesitamos tener un tiempo de transmisión de imágenes pequeño que nos garantice una comunicación fluida con el dron; si transmitiera imágenes en full HD es posible que la latencia de transmisión y postprocesamiento de la imagen introdujera un delay incómodo a la hora de controlar el dron ya que el ancho de banda de conexión entre el dron y el sistema es limitado 7.7.4.

- **Conectividad:** Es un quadrotor que se comunica vía **Wi-Fi** con smartphones o tablets por medio de una aplicación propia tanto en la banda de **2.4GHz** como en la **5GHz** y da la opción de seleccionar el canal por el que transmitir para asegurarnos de escoger el que menos interferencias tenga. También nos permite establecer una contraseña con seguridad WPA2 para evitar que otra persona se conecte al dispositivo.

Cuenta con GPS pero desarrollaremos esta característica en el apartado de *movimiento*.

También dispone de un puerto **micro USB** para conectarnos al microcontrolador de abordo para poder actualizar o modificar el firmware del dispositivo.

- **Movimiento:** Alcanza unas velocidades máximas de **60km/h en horizontal** y **21km/h en vertical** en 14 segundos y es capaz de frenar por completo en 4 segundos. Además soporta ráfagas de viento de hasta 60km/h.

Tiene su propio sistema de seguimiento (**tracking**) que funciona realmente bien. El movimiento autónomo es muy preciso y se puede ajustar la distancia que separa al dron del objeto de grabación así como las velocidades de rotación y movimiento lineal. Además existen kits de **FPV** (*First Person View* o Visión en Primera Persona en un modo de pilotaje con visión remota [28]) para volar el dron de manera manual a mayor distancia que permiten ver desde la perspectiva del dron.

Incluye su propio sistema **GPS** lo cual permite hacer planes de vuelo sobre el terreno y que el dron ejecute los movimientos secuencialmente hasta acabar el recorrido. También permite la opción *volver a casa* que hace volver al dron hasta el punto donde inició el vuelo.

- **Hardware y características físicas:**

- Batería de 2700mAh que suponen 25min de autonomía
- Hélices flexibles que se bloquean en caso de contacto
- LED trasero visible a larga distancia

- GPS
- Procesador de 2 núcleos
- GPU de 4 núcleos
- 8GBs de memoria flash
- 4 motores sin escobillas
- Peso de 500g
- Estructura de fibra de vidrio y grilamid

3.5. Ordenador

La instalación y ejecución del proyecto se ha realizado en un ordenador de sobremesa con las siguientes características:

- CPU: i7-4970K
- GPU: NVIDIA GTX 970
- RAM: 16GB DDR3
- WIFI: Banda dual 2.4GHz y 5GHz

Lo más apropiado para el proyecto sería utilizar un ordenador portátil para poder tener mayor movilidad a la hora de volar el dron, pero debido a que el equipo con el que contábamos no disponía de tarjeta gráfica, tuvimos que optar por utilizar el ordenador de sobremesa.

La tarjeta gráfica es un componente esencial en este proyecto ya que es la encargada de calcular las detecciones y trazados (*tracks*) en las imágenes obtenidas del dron. Este proceso es, computacionalmente, muy costoso; de hecho, en el equipo descrito, se ha conseguido un máximo de *13 fps* (*frames per second* o imágenes por segundo) durante la ejecución teniendo una media de *12 fps*. Esta cantidad es suficiente para probar el proyecto y realizar pequeños experimentos pero se recomienda utilizar tarjetas gráficas más potentes o un mayor número de ellas. En la web oficial de YOLOv3 [29] nos indican que, con una gráfica Pascal Titan X, se obtienen *30 fps* en el procesado del subconjunto de prueba *test-dev* del conjunto de datos *COCO* con una precisión media (mAP) del 57.9 %.

4. Diseño

La aplicación cuenta con únicamente dos nodos ROS. Uno implementa los drivers del dron y el segundo contiene el proyecto en sí mismo.

Este último nodo cuenta con el software de visión por computador, el software que implementa el comportamiento reactivo, y un pequeño script que nos permite capturar el vídeo de una webcam. Estas tres funcionalidades tan bien diferenciadas podrían (y deberían) haber sido separadas en tres nodos diferentes. ¿Por qué no se hizo entonces? Como hemos mencionado anteriormente, el proyecto se comenzó a desarrollar en un portátil de limitada potencia. El aumento de nodos implica un aumento de procesamiento paralelo que añadido a la sobrecarga intrínseca de la CPU al realizar el procesamiento gráfico, sería fulminante para el rendimiento. Por ello se diseñó el sistema con únicamente dos nodos (los estrictamente necesarios) y se mantuvo así para proceder lo antes posible con la implementación del código y estar seguros de tener una versión funcional del proyecto a tiempo para la fecha de entrega.

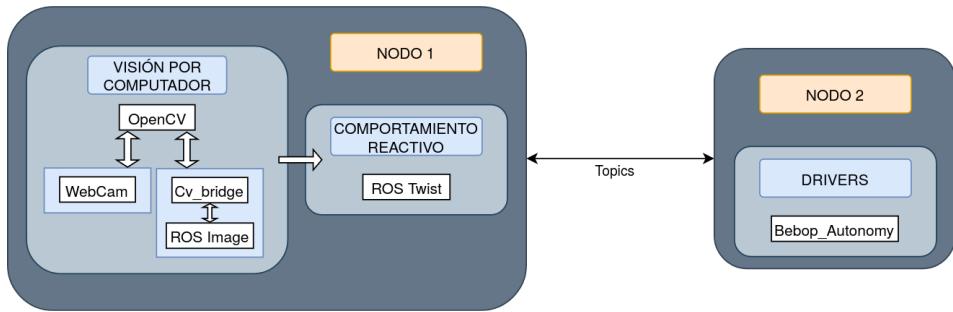


Figura 22: Esquema de nodos ROS en la aplicación

El *NODO 1* se corresponde con el PC y el *NODO 2* con el dron Bebop 2

Ambos nodos son emisores y receptores de mensajes ROS dependiendo del *topic* en cuestión.

- El *NODO 1* publica en los *topics*: cmd_vel, takeoff, land, reset y record. A su vez está suscrito a: imageraw y BatteryStateChanged.
- El *NODO 2* tiene la configuración contraria al *NODO 1*. Está suscrito donde él publica y viceversa.

La comunicación entre los módulos funcionales de la aplicación es cíclica siendo el nodo del controlador el que inicia el intercambio de mensajes.

El nodo que implementa el driver transmite la imagen captada por el dron al otro nodo del sistema. Aquí entra al módulo de Visión por Computador donde se procesa realizando la detección y tracking de las personas que aparezcan en escena. Posteriormente se extraen una serie de atributos referidos a las medidas y coordenadas de los Bounding Boxes y al identificador asignado a cada uno de ellos. Estos datos son pasados como parámetros al software de comportamiento del dron donde se tomarán las decisiones de movimiento oportunas basándose en la valoración de los datos obtenidos.

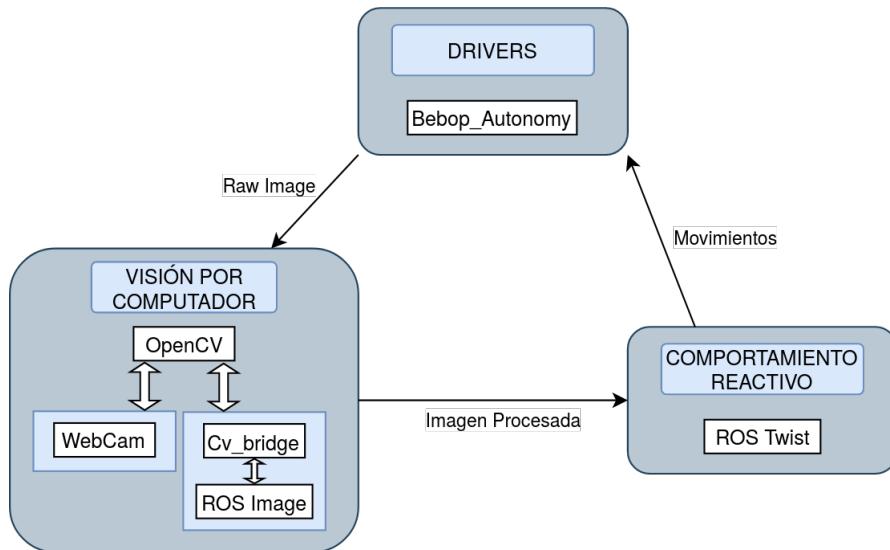


Figura 24: Esquema de comunicación entre los módulos de la aplicación

Si incluimos el análisis del video de la webcam lo que hacemos es realizar el tracking también de esta escena, permitiendo seleccionar un objetivo de manera que si este se sale del campo de visión, se manda una orden de despegue al dron.

Si utilizásemos un sistema de posicionamiento 3D que nos proporcionara la localización espacial del objetivo, podríamos llevar al dron directamente hasta la zona y empezar la búsqueda y el seguimiento activo. Este es, realmente, el enfoque más interesante del proyecto ya que se aproxima más a la idea de un sistema de video vigilancia plenamente autónomo en el que no se depende de ninguna persona física que inicialice el vuelo.

Como no disponemos de dicho sistema de posicionamiento nos remitimos, únicamente, a despegar el dron.

Si utilizamos el modo de pilotaje manual, los módulos de *Visión por Computador* y *Comportamiento Reactivo* quedan casi totalmente inutilizados. El módulo de visión tan sólo se encarga de mostrar por pantalla la cámara del dron para poder pilotarlo, y el módulo de comportamiento habilita una interfaz de usuario para poder indicar qué movimiento debe realizar el dron.

5. Implementación

Nos vamos a centrar en explicar la implementación de las funcionalidades que presenta el *NODO 1* de la figura 22 ya que es el que se ha desarrollado a lo largo del proyecto.

5.1. Visión por Computador

En este módulo nos encontramos con varias funcionalidades. Vamos a tratarlas en el orden en que se ejecutan cuando iniciamos la aplicación.

5.1.1. Captación de imágenes del dron

Para poder trabajar con las imágenes captadas por el dron debemos suscribirnos al topic `/bebop/image_raw` mediante la biblioteca *rospy* de python.

```
rospy.Subscriber("/bebop/image_raw", Image, callback_function)
```

Con esta línea nos suscribimos al topic y obtenemos en la función *callback_function* el mensaje ROS tipo `Image` pero este no es un formato válido con el que podamos trabajar. Es aquí donde entra en juego la biblioteca *cv_bridge* que obtiene, del mensaje `Image`, la imagen en sí misma mediante el método *imgmsg_to_cv2*.

```
self.bridge = CvBridge()
img = self.bridge.imgmsg_to_cv2(data, "bgr8")
```

De esta manera la imagen *img* se actualiza cada vez que hay una nueva publicación en el topic por parte del dron. Si quisieramos procesar todos y cada uno de los frames que obtenemos del bebop debemos guardar las imágenes obtenidas a medida que las transformamos. Debemos almacenarlas porque casi con total seguridad, la velocidad de captación de imágenes será mayor que la velocidad a la que las procesamos. Lo más lógico es usar un contenedor tipo cola dada su naturaleza para mantener el orden de los datos insertados y su estructura FIFO (First In First Out). En nuestro caso, no queremos procesar todos los frames ya que esto puede generar un retraso entre el frame que se está procesando y el frame recién captado que, además, irá aumentando durante la ejecución. Esto hará que la reactividad del dron disminuya o que, directamente, desaparezca. Por esto, la lectura de frames será asíncrona y cada vez que recibamos un frame del dron será considerado como el siguiente a tratar.

5.1.2. Captación de imágenes de la webcam

Dado que no hemos implementado un nodo que albergue la webcam, el proceso de obtención de las imágenes es mediante el método *VideoCapture(cam_path)* de OpenCV. Si implementamos la webcam como un nodo de ROS podemos usar el paquete *usb_cam* que habilita el topic '*camera_name*'/*image_raw* que utiliza el mismo tipo de mensaje ROS que el topic de Bebop Autonomy (*sensor_msgs/Image*). Por lo tanto el método de lectura del streaming de vídeo sería igual que en el apartado anterior.

Como decimos, en este caso utilizamos directamente los métodos de lectura de OpenCV. Con la webcam volvemos a tener el mismo problema que antes: necesitamos una lectura asíncrona que nos permita tener el menor retraso posible entre el frame captado y el frame procesado. Para ello creamos una nueva hebra que se encarga de leer constantemente el path de la cámara y sobrescribir el frame que consideramos como siguiente a procesar.

5.1.3. Lectura de archivo de vídeo almacenado

En pos de realizar pruebas sin tener que volar el dron, el software de visión nos permite abrir archivos de vídeo almacenados sobre los que realizamos detección y tracking de personas como si se tratase de un vuelo real. Cuando realizamos este tipo de pruebas, en vez de enviar comandos al dron, lo que hacemos es mostrar por pantalla cuáles serían esos comandos.

Al analizar un archivo de vídeo almacenado, sí realizamos una lectura síncrona de los frames ya que no necesitamos tener la reactividad que sí es crucial en un vuelo real. Lo que sí podemos hacer es establecer un intervalo según el cual iremos leyendo los frames a saltos. Si el intervalo es 1 la lectura será totalmente secuencial y síncrona. Si, por ejemplo, el intervalo es 3, significa que leeremos los frames 0,3,6,9,... En definitiva los frames que sean múltiplo del intervalo indicado. Esto permite que la ejecución dure menos tiempo y también que el experimento se asemeje más a la situación de un vuelo real en el que la lectura de imágenes es asíncrona y los frames no son consecutivos.

5.1.4. Escritura de vídeo

Disponemos de una funcionalidad para grabar localmente en el equipo servidor los fotogramas procesados (aparecen los Bounding Boxes) durante la ejecución del proyecto. Además, se crea un archivo de texto (cuyo nombre es el path de vídeo de entrada indicado al ejecutar la aplicación) donde indicamos el número de ejecución, la resolución a la que se han procesado las imágenes, el máximo, el mínimo y la media de *fps* obtenidos, y el total de tracks obtenidos.

```

1 Ejecución: 1
2 res: (854, 480)
3 Max FPS: 6.04919506618
4 Min FPS: 0.0847444394786
5 Mean FPS: 5.71171140017
6 Max track: 1
7 *1*
8 Ejecución: 2
9 res: (854, 480)
10 Max FPS: 6.13637612589
11 Min FPS: 0.085257671313
12 Mean FPS: 5.40591759105
13 Max track: 1
14 *2*
15 Ejecución: 3
16 res: (854, 480)
17 Max FPS: 6.40755262922
18 Min FPS: 0.087412801942
19 Mean FPS: 6.06396340888
20 Max track: 10
21 *3*
-- -- . .

```

Figura 25: Ejemplo de archivo txt generado

5.1.5. Tracker - DeepSORT

Utilizamos DeepSORT [5] como algoritmo de tracking por ser puntero en la tarea que ocupa. Se trata de una actualización, una mejora del algoritmo SORT (Simple Online and Real-time Tracker) en la que aplicamos *deep learning*. Utiliza filtros de *Kalman* para predecir la posición de futuros tracks basándose en las detecciones actuales y tracks pasados. Para asignar estos nuevos tracks a los antiguos utiliza dos algoritmos: *Distancia Mahalanobis* [30] y *Algoritmo Húngaro* [31].

Donde aplicamos *Deep Learning* es en una última métrica para la reasignación de trackers (Referencia: [5]. Apartado: *The appearance feature vector*). Esta nueva métrica se basa en la apariencia de los tracks. Extraemos un vector de características de cada track y lo enlazamos (*match*) con aquel cuyo vector sea más parecido (menor similitud de coseno. No puede ser consigo mismo). Este vector de características es el obtenido en la última capa de la CNN de nuestro detector: YOLOv3 [4].

5.1.6. Detector - YOLOv3

Como algoritmo de detección utilizamos la red neuronal convolucional (CNN) YOLOv3, un sistema de detección en tiempo real de última generación, que nos aporta gran precisión y rapidez a la hora de detectar y clasificar objetos.

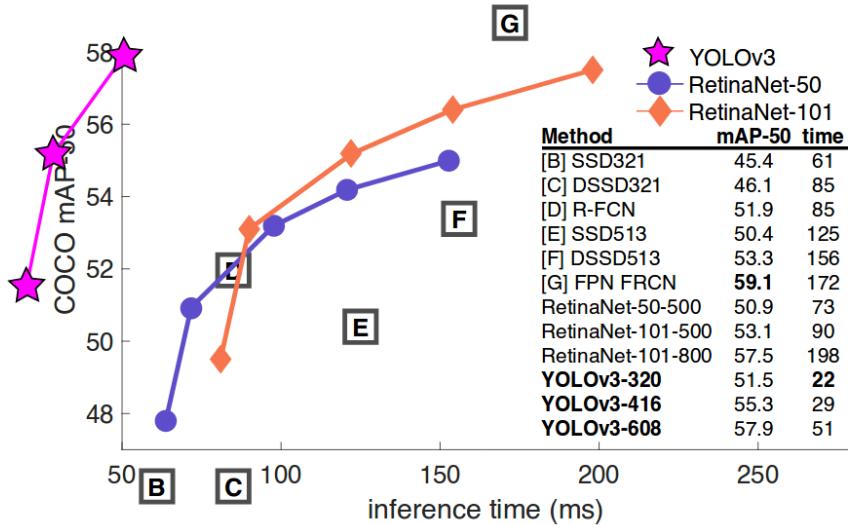


Figura 26: Rendimiento de YOLOv3 frente a otros algoritmos de detección

Paper: [4]

Mediante YOLO obtenemos los Bounding Boxes de los objetos (personas) detectados junto con la probabilidad de que el objeto detectado pertenezca a X clase; en nuestro caso, a la clase *persona*. Son los datos relativos a los Bounding Boxes los que se transmiten al tracker: coordenadas en la imagen de la esquina superior izquierda de la detección y la altura y la anchura del rectángulo.

5.2. Comportamiento del Dron

5.2.1. Pilotaje Manual

Como decíamos en 4, el módulo de visión es útil sólo para mostrar por pantalla la imagen captada por el dron para así poder pilotarlo.

La aplicación despliega un menú de ayuda que muestra los controles asociados a cada movimiento del dron.

```
[0] Modo manual
[1] Seleccionar target video principal (solo funciona en modo automatico)
[2] Seleccionar target video secundario
[3] Seleccionar velocidad [0.0 - 1.0]
[4] Empezar/Parar grabacion
[5] Mostrar % bateria
[p] Parada de emergencia
[q] Salir del programa
[h] Help

0

[ ] Despega
[l] Aterrizar
[w] Avanza
[a] Desplaza izda
[s] Retrocede
[d] Desplaza dcha
[8] Asciende
[4] Gira izda
[6] Gira dcha
[2] Desciende
[5] Para
[e] Exit. Modo auto
[p] Parada de emergencia
[h] Help
```

Figura 28: Menú principal + Menú de pilotaje manual

Las acciones $w,a,s,d,8,4,6,2$ se ejecutan de manera continuada una vez se seleccionan, es decir, si pulsamos, por ejemplo, w el dron avanzará indefinidamente sin necesidad de mantener o pulsar repetidamente la tecla. Para detener el movimiento debemos pulsar 5 para que el dron quede flotando estático en el aire.

Si se pulsa e salimos del modo manual y, en caso de que hubiésemos indicado un track ID al que perseguir y este siga activo, el dron retomaría la persecución. La acción p envía un mensaje al topic *reset* lo que provoca la parada inmediata de los cuatro motores del dron.

5.2.2. Pilotaje Automático

En este modo necesitamos seleccionar el ID del track que marca la persona a la que queremos perseguir. Para ello, desde el menú principal 28 tecleamos 1 para acceder al diálogo de selección. En este diálogo se nos pide el ID de la persona a seguir y sólo podemos introducir un identificador válido o '-1' en caso de querer salir del diálogo sin seleccionar ningún objetivo.

```
[0] Modo manual
[1] Seleccionar target video principal (solo funciona en modo automatico)
[2] Seleccionar target video secundario
[3] Seleccionar velocidad [0.0 - 1.0]
[4] Empezar/Parar grabacion
[5] Mostrar % bateria
[p] Parada de emergencia
[q] Salir del programa
[h] Help

1
'-1'Exit.
Select target:
2
Bad Target. Select one of this:
[1]
'-1'Exit.
Select target:
1
Target Updated
```

Figura 29: Diálogo de selección de objetivo

En el momento en que indicamos un identificador válido, los atributos del Bounding Box (BB) asociado se envían al método de seguimiento. Aquí se toman las decisiones sobre qué movimiento realizar dependiendo de los valores de estos atributos.

Hemos fijado unos márgenes tanto en el eje X (40 % y 60 % del ancho de la imagen) como en el eje Y (40 % y 60 % de la altura de la imagen) entre los cuales intentaremos mantener siempre el *centroid* (punto medio) del BB. Si el centroid pasa a estar en [0,40) % en el eje X, rotaremos el dron hacia la izquierda para tratar de llevar el punto medio de nuevo entre los márgenes. Si, por el contrario se encuentra en (60,100] %, rotaremos hacia la derecha. Si sobrepasamos los límites verticales del eje Y ascenderemos en el caso de estar en [0,40) % y descenderemos si se encuentra en (60,100] %. Con la altura del BB, controlamos la distancia a la que nos encontramos del objetivo. También disponemos de unos márgenes entre los cuáles puede estar. La implementación de esta histéresis en el sistema evita que el dron esté continuamente moviéndose descontroladamente y permite tener un movimiento más fluido para obtener una imagen más clara. Si la altura del BB es demasiado grande, el dron se alejará del objetivo y si es más pequeña, se acercará.

5.2.3. Opciones Menú Principal

- **0:** Entra en modo manual y deja de perseguir al objetivo (si es que lo tenía).
- **1:** Permite introducir el ID del objetivo que vemos por el streaming de vídeo principal.
- **2:** En caso de ejecutar la aplicación sobre el vídeo proporcionado por el dron y el vídeo proporcionado por una webcam o cámara fija simultáneamente, permite introducir el ID del objetivo que vemos por el streaming de vídeo de la webcam.
- **3:** Nos permite introducir la velocidad de movimiento lineal y de rotación del dron. Por defecto la velocidad lineal es de 0.1 y la de rotación 0.07.
- **4:** Empieza/Termina la grabación en la memoria flash del dron de la imagen captada por el mismo.
- **5:** Nos informa del porcentaje de batería restante.
- **p:** Realiza una parada de emergencia. Funciona igual que en el pilotaje manual.
- **q:** Salimos de la aplicación.
- **h:** Muestra por pantalla las opciones disponibles del menú.

6. Problemas durante el desarrollo

6.1. Restricciones Harware

- El rango de conexión Wi-Fi es limitado. La área en la que podremos volar el dron será, aproximadamente, una circunferencia de 30 metros de radio con centro el servidor.
- El servidor, en mi caso, es un ordenador de sobremesa por lo que no puedo transportarlo a mi gusto y llevarlo a zonas amplias y despejadas en las que volar el dron, si no cuento con un suministro eléctrico.
- La iluminación debe ser adecuada para permitir que la detección y seguimiento (*tracking*) sean adecuados, debido a la apertura focal de la cámara del dron.
- El dron Bebop funciona con baterías por lo que, eventualmente, habrá que cambiarla para proseguir con la ejecución o, en caso de no disponer de una de repuesto, inhabilitar el sistema hasta que se haya recargado.
- Necesitamos una gráfica NVIDIA para poder realizar los cálculos de los algoritmos de visión por computador.
- La interacción humano-máquina se ha desarrollado a través de la terminal de Linux por lo que obligatoriamente debemos disponer de un teclado.

6.2. Restricciones Software

- Para ejecutar el proyecto es necesario hacerlo sobre ROS Kinetic.
- ROS Kinetic solo está disponible para Ubuntu 16.04 por lo que deberemos disponer de este Sistema Operativo.
- Necesitamos Python 2.7 para la ejecución del proyecto tanto para la parte de visión por computador como para la que implementa el comportamiento del dron.

6.3. Restricciones Sanitarias

Debido a la particular situación sanitaria que estamos viviendo en este año 2020 a causa del COVID-19, me he visto limitado en ciertos aspectos a la hora de desarrollar este trabajo de fin de grado 6.4.

6.4. COVID-19

Antes de comenzar con problemas puramente técnicos he de mencionar los ocasionados por la crisis sanitaria del COVID-19. Debido a la emergencia sanitaria, y las restricciones sociales derivadas de ella, el proyecto se ha visto afectado en los siguientes puntos:

- No he podido recurrir a las instalaciones del CITIC para realizar los vuelos del dron en la jaula de la que disponen allí específicamente orientada a ello.
- Tampoco he considerado la opción de buscar un equipo portátil con suficiente potencia para ejecutar el proyecto, ya que no hubiese podido salir a realizar vuelos al aire libre debido al confinamiento.
- No han sido posibles las reuniones presenciales con mis tutores para resolver dudas de una manera más clara y sencilla.
- Por todo lo anterior el proceso de experimentación ha sido mucho más limitado.

Durante esta situación nos hemos centrado mucho más en la investigación de algoritmos más eficientes, en cómo podíamos ajustar más los algoritmos de detección y seguimiento a nuestro caso particular, en el desarrollo de un comportamiento autónomo más eficiente... Aunque esto último, se hizo de manera “intuitiva” ya que no pudimos probar los resultados hasta prácticamente un mes antes de la entrega.

6.5. Problemas Técnicos

A lo largo del proyecto nos hemos encontrado con diversos problemas de naturaleza tanto física como a nivel de software. Los descritos a continuación son los que han ocasionado largas pausas durante el desarrollo y que han supuesto un mayor trabajo de investigación para intentar solventarlos.

6.5.1. Virtualización

En un primer momento si intentó desarrollar el proyecto en una máquina virtual con *VirtualBoX* [32] pensando en la portabilidad del proyecto y la posibilidad de ejecutarlo en un equipo Windows. El problema de la virtualización es que no podemos aprovechar los recursos en su totalidad y en especial el uso de la tarjeta gráfica y la instalación de *CUDA* [33] es realmente complicado desde una VM con Ubuntu 16.04. Estas trabas durante la instalación de controladores y paquetes, y la incomodidad intrínseca de trabajar en una VM, hicieron que descartara esta idea.

6.5.2. Equipo de Trabajo

Como se ha sugerido en 3.5 lo más apropiado es realizar la instalación del proyecto en un equipo portátil para poder tener mayor libertad de movimiento. Fue así como se inició el trabajo. El portátil consta de:

- CPU: i5-7200U
- GPU: integrada
- RAM: 4GB DDR3
- WIFI: Banda dual 2.4GHz y 5GHz

El gran problema, como dije antes, es que carece de una tarjeta gráfica que realice los cálculos de detección y seguimiento (*tracking*). Ejecutando el proyecto final en este ordenador hemos llegado a obtener picos de 0.8 *fps* pero la media ronda los 0.7 *fps*. Claramente esto es insostenible y es imposible realizar pruebas y experimentos si no llegamos ni a recibir 1 frame por segundo. La reactividad del dron es inexistente.

Figura 30: La imagen muestra la evolución de la cantidad de *fps* y tracks detectados a lo largo de los frames obtenidos. Como vemos, los *fps* rondan los 0.7. Analizaremos esta gráfica en mayor profundidad más adelante en el apartado de experimentación.

Una posible solución a estudiar sería realizar el cálculo más pesado en la nube: alquilar un servidor que cuente con herramientas que permitan la ejecución de algoritmos de *Machine Learning* (que cuenten con bibliotecas específicas como tensorflow o keras, y unas prestaciones hardware a la altura de las necesidades del proyecto). Respecto a esta opción, habría que estudiar cómo realizar el intercambio de información (tipos de datos, cantidad de información, frecuencia de peticiones...) y cómo afectaría esta implementación a los tiempos de respuesta del dron.

Este enfoque no se ha llevado a cabo debido al poco tiempo disponible y a limitaciones económicas, pero es una opción interesante que me gustaría retomar.

Finalmente, para continuar con el desarrollo, adquirí una tarjeta Wi-Fi para el ordenador de sobremesa. Con ella fue posible conectarnos de nuevo al dron y continuar con las pruebas.

6.5.3. Límite de Distancia de Conexión

Con la resolución del punto anterior nos surge un nuevo problema: dado que nuestro equipo servidor es local y estático, las posibles zonas de vuelo del dron se reducen a los alrededores de mi vivienda y, aunque por suerte, hay un descampado justo al lado, la distancia dron-servidor es límite, provocando que eventualmente se pierda la conexión durante las pruebas.

Se intentó crear una red de nodos que funcionasen como repetidores de la señal Wi-Fi del dron Bebop 2 configurando una serie de *routers* en modo puente (*bridge*). Esta idea no tuvo éxito y, debido al corto plazo de tiempo del que disponíamos, decidimos no seguir ahondando en esta dirección. Finalmente decidimos conformarnos con la distancia que nos proporciona el Wi-Fi a 2.4Gh.

Esta situación de experimentación ha sido excepcional, al igual que lo ha sido la situación sanitaria en la que nos hemos visto envueltos estos últimos meses por el COVID-19. El desarrollo de las pruebas debería haberse realizado en el CITIC [34], que cuenta con una jaula específica para el vuelo de drones.

6.5.4. Python y DeepSORT

ROS Kinetic trabaja con python2.7, el cual ha dejado de tener soporte desde principios de este año 2020. Esto ha supuesto muchos problemas ya que los algoritmos de detección y seguimiento (*tracking*) desarrollados para Python2.7 tienen dependencias de paquetes que ya no es posible descargar. Finalmente encontramos un algoritmo de detección más seguimiento (*tracking*) casi totalmente funcional con python2: una implementación del algoritmo Deep SORT [5] por parte del usuario *Qidian213* en GitHub [35]. El algoritmo nos da un error por la falta de una biblioteca pero esto está resuelto en uno de los *issues* del repositorio [36].

Antes de encontrar este código intentamos dar otra solución, específicamente la comentada en el siguiente apartado.

6.5.5. Instalación de ROS2 junto a ROS Kinetic

Como hemos dicho, Python2 ha dejado de tener soporte y gran cantidad de software ha quedado obsoleto debido a ello. Además, se ha desarrollado nuevo software y nuevas versiones de antiguos algoritmos para Python3 (que si cuenta con soporte) mucho más eficientes.

Por esto tratamos de construir el proyecto sobre un entorno que nos brindara una mayor libertad en el desarrollo. Este entorno se trata del framework ROS2, la nueva versión de ROS que permite trabajar, como decimos, con Python3 y que además está disponible para versiones de Ubuntu más actualizadas, con mayor número de paquetes, y que ofrecen soporte a más largo plazo: Ubuntu 18.04 y Ubuntu 20.04.

El problema comienza a la hora de instalar el driver *Bebop Autonomy* ya que sólo está disponible para la versión *Kinetic* de ROS. Para intentar suplir esto, se intentó realizar una instalación conjunta de ambas versiones del framework ROS y ROS2 y establecer un puente entre ellas de manera que el driver del dron se ejecutara en ROS y el algoritmo reactivo en ROS2 haciendo uso de Python3.

Tras numerosos intentos fallidos tanto en la instalación conjunta de los frameworks, como en el establecimiento del puente entre los mismos, decidimos volver al enfoque inicial: buscar un tracker o, en su defecto, desarrollarlo, para que funcione con python2 y así poder usarlo en una instalación limpia de ROS Kinetic.

6.5.6. Demo práctica del repositorio de *Qidian213* poco eficiente

La demo proporcionada en el repositorio tiene tres principales problemas:

- Requiere de una biblioteca de lectura asíncrona que no se encuentra en el repositorio. Está solucionado en uno de los *issues* [36].
- Ejecuta dos veces el algoritmo de detección por frame. Esto es innecesario y muy poco eficiente.

```
71      boxes = yolo.detect_image(image)[0]
72      confidence = yolo.detect_image(image)[1]
```

Figura 31: Detección ineficiente en demo.py

Imagen obtenida del repositorio de Qidian213 [35]

- Realiza detección de la escena en cada fotograma, cuando la idea en un algoritmo de seguimiento (*tracking*), es realizar la detección cada X fotogramas de manera que en las imágenes intermedias sea el tracker el que estime la futura posición de la figura. Esto también conlleva unos resultados poco eficientes.

En nuestra implementación en particular, se ha escogido un periodo de detección de 3 frames. Un periodo inferior de 2 frames no proporciona una mejora notable y un periodo de 1 frame es igual que la implementación de *Qidian213*. Con periodos de detección mayores, empezamos a notar la pérdida de consistencia en los trazados (*tracks*).

El periodo de 3 frames, consigue una mejora de rendimiento más que notable que se traduce en una mayor fluidez del vídeo procesado y mayor reactividad en el comportamiento del dron.

Retomaremos este tema en el apartado de experimentación y pruebas.

Problema	Plan de contingencia. Primera Idea	Solución Final
Confinamiento + Bajo rendimiento del algoritmo de seguimiento	Dedicación al desarrollo conceptual del proyecto e investigación de algoritmos	Hallazgo del algoritmo de seguimiento (<i>tracker</i>) funcional en python2.7. Arreglar su código y adaptarlo a nuestro proyecto.
Requiere versión de sistema operativo antigua	Virtualización	Instalación limpia de Ubuntu16.04
Recursos hardware limitados en equipo portátil	Cómputo pesado en la nube	Traslado del desarrollo y ejecución del proyecto al ordenador de sobremesa. Supuso adquirir nuevos módulos de RAM y una tarjeta Wi-Fi
Límite de distancia de conexión y, por tanto, límite de la zona de vuelo	Diseño de una red de repetidores de la señal Wi-Fi del dron Bebop 2	Seguir trabajando con la cobertura dada por la señal Wi-Fi original del dron
Python2.7 obsoleto	Búsqueda de algoritmos que funcionen con Python3. Instalar versiones de ROS que trabajen con Python3	Hallazgo de algoritmo funcional con Python2.7. Instalación de ROS Kinetic
Driver del dron no funciona en versiones de ROS distintas a Kinetic	Instalación conjunta de ROS2 y ROS Kinetic en Ubuntu 18.04 o 20.04	Utilizar ROS Kinetic

Cuadro 4: Tabla sintetizada de problemas, planes de contingencia y soluciones finales

7. Experimentación

Métricas

Las comparaciones se realizaran enfrentando los resultados obtenidos en:

- Número total de frames procesados
- Tiempo total de procesamiento (*segundos*)
- Tiempo medio de procesamiento por frame (*segundos*)
- FPS (*fotogramas por segundo* procesados. La inversa del dato anterior nos da una aproximación de este)
- Número total de tracks detectados

Procedimiento

En primer lugar pondremos a prueba la eficacia del detector YOLOv3 [29] ya que su rendimiento depende únicamente de la primera métrica: la resolución de la imagen. La prueba la realizaremos sobre el benchmark MOT17_12 y con ella pretendemos decidirnos por una resolución con la que trabajar en el resto de experimentos.

En segundo lugar, compararemos el rendimiento del algoritmo haciendo pruebas sobre el benchmark MOT17_05 con distintas configuraciones de valores para los parámetros del sistema. Esto lo haremos para tratar de encontrar la configuración ideal con la que poner a prueba la consistencia del tracker. Los parámetros del sistema son:

- Resolución de las imágenes procesadas (fijaremos este valor en la prueba del algoritmo de detección).
- Periodo de detección (cada cuántos frames realizamos detección de personas en la escena).
- Intervalo de procesamiento de frames (No procesar un determinado número de frames de forma periódica. Un intervalo de 1 frame implica una lectura completamente secuencial. Un intervalo de 3 frames implica leer solo los frames que ocupan una posición múltiplo de 3 en la secuencia de vídeo: 0, 3, 6, 9, 12, ...).

Después vamos a poner en cuestión la eficacia del algoritmo de seguimiento (*tracking*) ejecutando la aplicación con los parámetros que consideremos más adecuados según lo que hayamos concluido en el apartado anterior. Observaremos en las imágenes de salida de la aplicación el dibujado de los *Bounding Boxes* y sus correspondientes IDs para valorar si se trata de un buen resultado o no.

Por último realizaremos la prueba de vuelo del dron analizando también el procesamiento del vídeo obtenido.

Resultados

Todos los resultados se encuentran disponibles en la carpeta de MEGA [21]. Encontraremos resultados antes y después de la corrección del código de *Qidian213* 6.5.6.

7.1. Pruebas del Detector

7.1.1. Oclusión

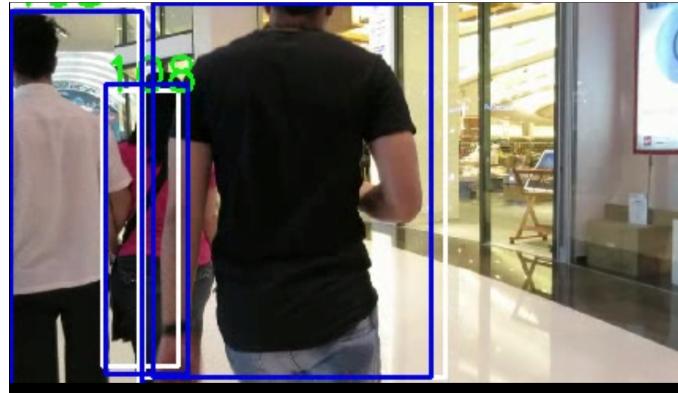


Figura 33: MOT17_12 imagen:0 426x240

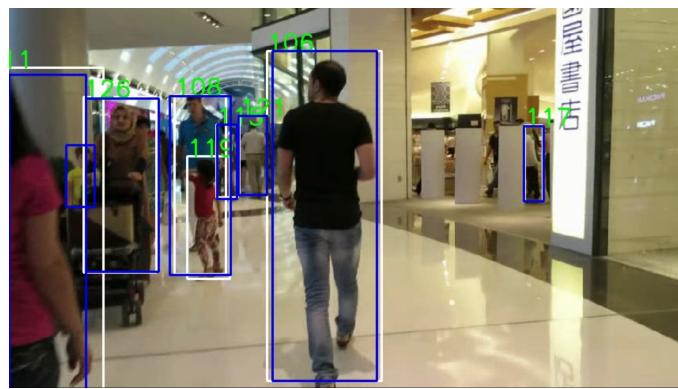


Figura 34: MOT17_12 imagen:1 854x480

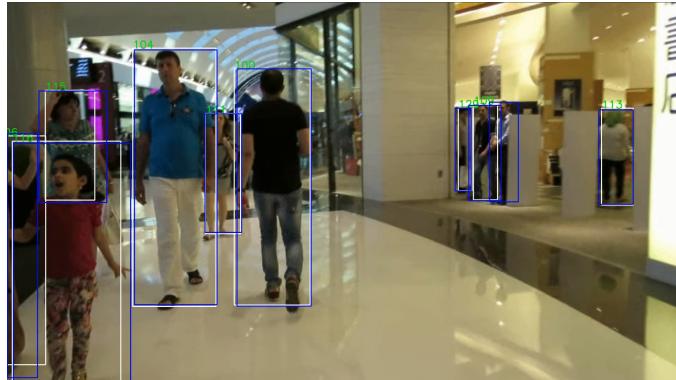


Figura 35: MOT17_12 imagen:2 1920x1080

A la hora de medir la eficacia de la detección de personas en situaciones con oclusión entre figuras, solamente interviene en el resultado la resolución de la imagen ya que, mediante los otros dos parámetros, lo único que puede variar es que se realice o no la detección de personas en ese frame concreto. Nosotros queremos evaluar su eficacia por lo que queremos que sí o sí se realice la detección en el fotograma. Para ello ajustamos un periodo de detección igual a 1 (realizamos detección en todos los frames), y un intervalo de lectura también igual a 1 (realizamos una lectura completamente secuencial del vídeo, procesamos todos sus fotogramas).

El algoritmo de detección se desenvuelve bastante bien ante la oclusión de figuras. Hemos probado su eficacia con distintas resoluciones (muy dispares entre ellas) y en todas hemos obtenido un muy buen resultado. Las resoluciones vienen indicadas en el pie de la figura.

En la primera imagen podemos ver como detecta a la mujer marcada con el identificador 108 que se encuentra entre dos personas que tapan parte de su cuerpo.

En la segunda fotografía vemos que detecta al hombre etiquetado con 108 a pesar de que una niña tapa la mitad inferior de su cuerpo. También vemos la detección de un niño que todavía no ha sido “*traqueado*” (no se ha calculado su trazado o *track*) que se encuentra detrás del carro de bebés.

Por último, en el tercer frame, vemos una persona identificada con 111 tapada por el hombre 104, y a la mujer 115 tapada por la niña 116.

Resultados de Interés

Durante la ejecución de la aplicación sobre este benchmark a distintas resoluciones nos hemos percatado de cómo influye el tamaño de la imagen que va a ser procesada en la velocidad de procesamiento. Cuanto más pequeña es la imagen (menor resolución), menos tiempo toma su procesamiento y, por tanto, mayor es el número de *fps* que obtenemos. Esto tiene sentido, si recordamos que el *modus operandi* del detector es recorrer las zonas de interés de la imagen para buscar en ellas figuras a clasificar. Cuanto menor sea la imagen, más pequeñas serán estas áreas y menos tardará el proceso de detección.

Resolución	FPS
426x240	9.4264
854x480	8.3094
1920x1080	5.6543

Cuadro 5: FPS frente a Resolución

Parámetros: periodo=1; intervalo=1

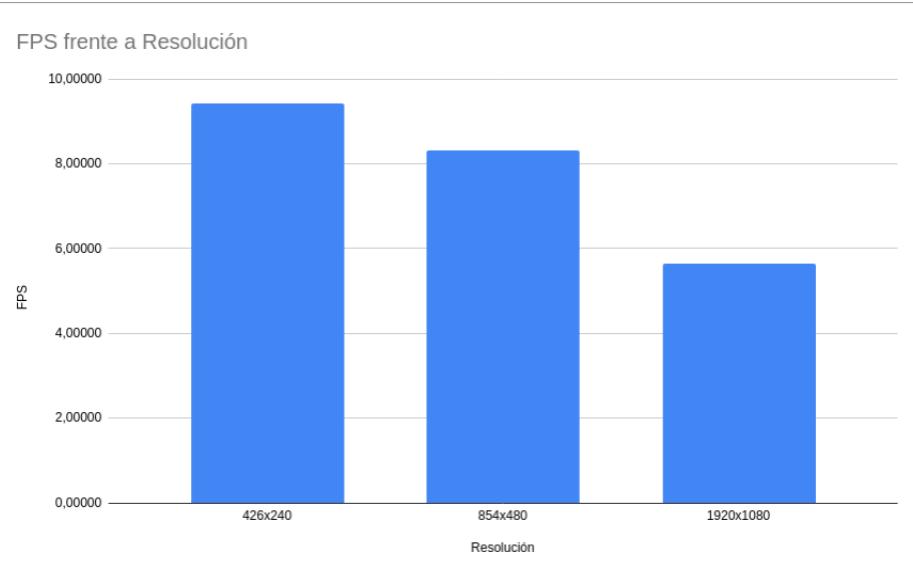


Figura 36: *fps* frente a la resolución de la imagen

Parámetros: periodo=1; intervalo=1

Ya que la resolución no altera la eficacia de la detección (o, al menos, no de una manera notable), usaremos 426x240 como resolución para realizar las pruebas ya que nos aporta un mayor número de *fps*.

Además, a menor resolución, mayor es el número de trazados calculados.

Resolución	Nº Tracks
426x240	183
854x480	163
1920x1080	157

Cuadro 7: Número de Trazados frente a Resolución

Parámetros: periodo=1; intervalo=1

Este incremento en los trazos calculados puede deberse a dos distintas situaciones:

- Al reducir la resolución de la imagen, el algoritmo de detección considera como áreas de interés zonas proporcionalmente mayores que en resoluciones más altas. Al ser (proporcionalmente) mayor la superficie de la imagen a explorar en busca de personas, somos capaces de detectar un mayor número de figuras en escena.
- El hecho de redimensionar la imagen a una resolución menor (*downsampling*), causa que la imagen se difumine y pierda nitidez (aplicamos un filtro de suavizado: Gaussian Blur [37]). Esto puede provocar que la extracción de características de las figuras no sea muy precisa y provoque la pérdida de trazados *tracks* que tengan que volverse a calcular. También es posible que debido a la falta de información de la imagen (falta de detalle) el algoritmo confunda otros tipos de figuras con personas.

7.2. Eficiencia del tracker DeepSORT en MOT Challenge

MOT Challenge o *Multiple Object Tracking Benchmark* [38] es una prueba de rendimiento que se aplica comúnmente a los algoritmos de tracking para compararlos entre sí. Hemos realizado las pruebas sobre tres de los catorce benchmarks disponibles en el desafío de 2017 (MOT17): MOT17_05, MOT17_06, MOT17_12. Como hemos mencionado en el apartado anterior 7.1.1, vamos a utilizar una resolución de 426x240 para realizar las pruebas.

7.2.1. MOT17_12

Al analizar las distintas pruebas realizadas, demostraremos que la fluidez de la ejecución depende mucho de las métricas nombradas al inicio de la sección y, también, del número de detecciones realizadas, que se verán reflejadas en el número de trazados (*tracks*) obtenidos. Esta última característica influye en el rendimiento debido a los costes computacionales que conlleva la detección de figuras. Cuantas más detecciones se realicen en un mismo frame, más cálculos se han de hacer y más tiempo se tarda en procesar el fotograma.

El intervalo de lectura del vídeo afecta al rendimiento ya que aumenta o disminuye el número de frames a procesar. De un vídeo de 60 frames, procesaríamos todos ellos si aplicamos un intervalo de 1 fotogramas. Pero si aplicamos un intervalo de 3 frames, el número de las imágenes procesadas disminuye a 20, lo que se traduce en un incremento de la reactividad del sistema ya que procesamos el mismo fragmento de vídeo en menos tiempo.

El periodo de detección nos indica cada cuántos frames recibidos, realizamos detección de personas en la imagen. Lo que conseguimos es reducir el número de veces que analizamos los fotogramas en busca de figuras, es decir, reducimos el coste de cómputo del detector tantas veces como indiquemos en el intervalo. Si designamos un periodo de 2 fotogramas, estaremos realizando detección en uno de cada dos frames y, por lo tanto, estamos reduciendo el tiempo de procesamiento del detector a la mitad. El tiempo de procesamiento del algoritmo de seguimiento o *tracker* no varía, por eso con un periodo de 2 fotogramas no conseguimos procesar el vídeo por completo en exactamente la mitad de tiempo que con un periodo de 1 frame.

Al valorar las pruebas nos centraremos en los *fps* obtenidos debido a la escasez de los mismos. Si contásemos con un equipo hardware que, de base, nos proporcionase un mayor número de cuadros por segundo, podríamos centrarnos en mejorar otras características como obtener el mayor número de detecciones (y por ende *tracks*) posibles o intentar usar el vídeo a mayor resolución para que la visualización de los resultados fuese más cómoda. Como este no es el caso, y contamos con un número reducido de *fps*, necesitamos ajustar los parámetros de ejecución de manera que aumentemos esta variable para que la reactividad de nuestro dron sea la mayor posible.

7.3. Comparación: Intervalo 1

Prueba 1:

- **Mean time:** 0.100563321681
- **Max track:** 183
- **FPS:** 9.42643260313
- **Frames Totales:** 899
- **Tiempo total:** 95.3701190948
- **Intervalo:** 1
- **Periodo:** 1

Esta se trata de la prueba más precisa de todas las que analizaremos y es de la que se ha obtenido el fotograma 33 mostrado en el apartado de Oclusión. Decimos que es la más precisa porque en ella leemos el vídeo al completo (no nos saltamos frames, intervalo=1) y realizamos detección en todos y cada uno de los fotogramas (periodo=1) aportando así la mayor consistencia posible al algoritmo de seguimiento (*tracker*). Por ello, escogemos nuestros parámetros ideales comparando los resultados obtenidos con los que aquí se muestran.

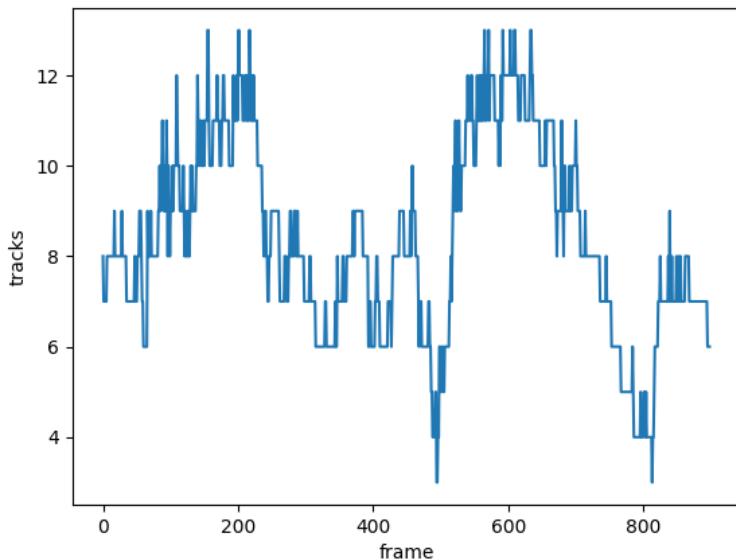


Figura 38: Número de tracks detectados por frame

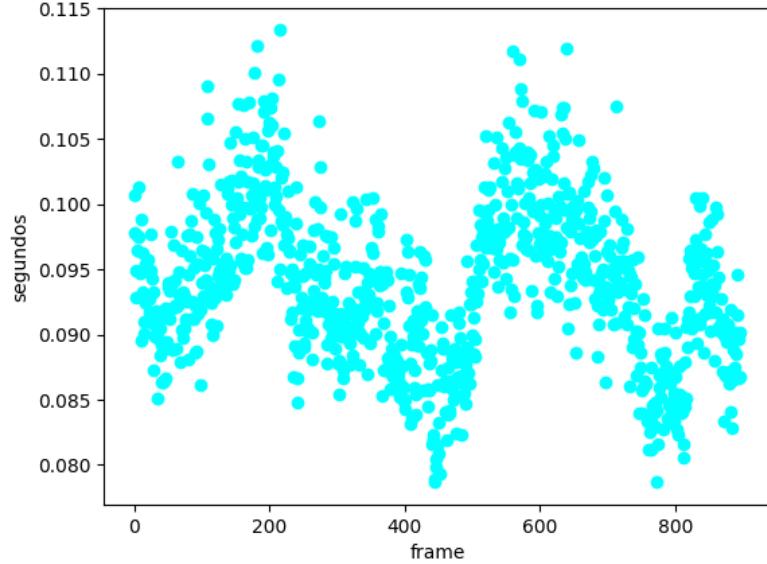


Figura 39: Tiempo de procesamiento requerido por frame

La relación entre ambas imágenes (38 y 39) es innegable. Como hablábamos al principio de la sección 7.2.1, la relación entre número de detecciones por frame y el tiempo de procesamiento de dicho frame es muy estrecha. Vemos como en ambas gráficas los valores toman la misma forma sobre los ejes. Todos los valles y crestas que nos encontramos en la gráfica de número de *tracks* por frame, se reflejan a la perfección en la gráfica que muestra los tiempos de procesamiento.

Prueba 2:

- **Mean time:** 0.0548581803866
- **Max track:** 736
- **FPS:** 16.9344600149
- **Frames Totales:** 899
- **Tiempo total:** 53.0870189667
- **Intervalo:** 1
- **Periodo:** 2

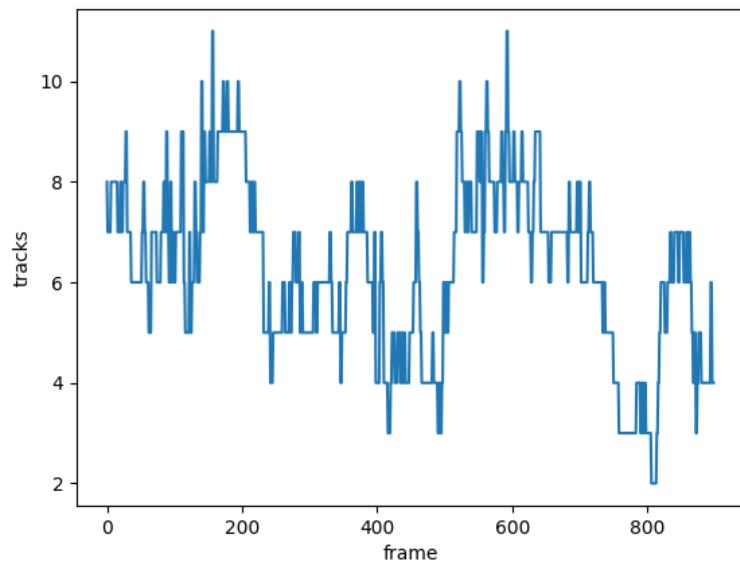


Figura 40: Número de tracks detectados por frame

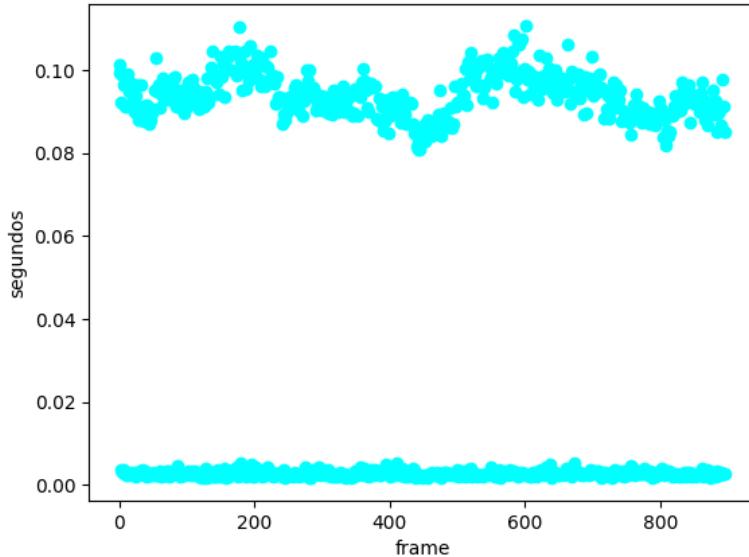


Figura 41: Tiempo de procesamiento requerido por frame

Vamos a empezar hablando sobre el número de tracks detectados en esta prueba. Por una parte la figura 40 nos indica que el pico de trazos (*tracks*) por frame ha disminuido, sin embargo, el recuento total de *tracks* calculados ha ascendido hasta cuatro veces el número de *tracks* de la primera ejecución. Esto es debido al periodo de detección cada dos frames. La inconsistencia de las detecciones a lo largo de la secuencia de vídeo propician cálculos fallidos de tracks, lo que hace que el número de estos aumente.

La otra diferencia notable la encontramos en la figura 41. Ahora vemos que los puntos se dividen en dos grupos: un grupo cuyo tiempo de procesamiento es muy cercano a 0.0 segundos, y otro formado por frames con un tiempo de cómputo mayor. Si nos fijamos bien, la distribución de los puntos de este último grupo se vuelve a asemejar a la gráfica de número de *tracks* por frame (Figura: 40). Esto es porque son los puntos de este grupo los correspondientes a los frames en los que se ha realizado detección de personas, mientras que, en los otros, tan sólo hemos dejado predecir al algoritmo de seguimiento (*tracker*) las futuras posiciones de los trazados. Con esto vemos claramente que las predicciones requieren un cómputo mucho menor que las detecciones y que el tiempo de cómputo de estas últimas depende mucho del número de personas en escena.

Debido al periodo de detección cada dos frames, hemos conseguido, prácticamente, 9 *fps* más que en la Prueba 1, pero hemos cuadruplicado el número de *tracks* calculados. A lo largo de las pruebas queremos encontrar una combinación de parámetros que nos aporte un número razonable *fps* a la vez que evitamos que el número de *tracks* calculados ascienda demasiado.

Resto de pruebas con Intervalo 1

Dado que el resto de gráficas son muy parecidas a las de la Prueba 2 y lo único a destacar en ellas es que los puntos del grupo de frames en los que se aplica detección cada vez son más distantes entre sí a medida que aumentamos el periodo de detección, vamos a realizar el resto de pruebas sin mostrarlas (se pueden consultar en la carpeta de MEGA [21]), obtendremos los resultados y los compararemos entre sí para decantarnos por una combinación de parámetros “ganadora”.

Si tomamos como referentes los datos de la primera prueba por ser la más precisa (procesamos todos los frames del vídeo y en todos ellos aplicamos detección), podríamos considerar el aumento de *fps* como una medida de mejora y, el aumento del número de trazados (*tracks*) calculados, como una medida de error. También mostramos cuánto supone el error respecto a la mejora obtenida para valorar más fácilmente que opción merece más la pena:

Periodo	FPS	Nº Tracks	Mejora (FPS / 9.43)	Error (Nº Tracks / 183)	Error / Mejora
1	9.4264	183	1	1	1
2	16.9344	736	1.8	4.02	2.23
3	23.0309	489	2.44	2.67	1.095
4	27.9869	837	2.97	4.57	1.54
5	20.7414	730	2.2	3.99	1.81

Cuadro 9: Resultados de ejecución en MOT17_12

Constantes: intervalo=1, resolución:426x240

Tras analizar los resultados obtenidos, vemos que una muy buena opción es la ejecución de la aplicación con un periodo de detección de 3 frames, ya que nos aporta 2.44 veces más frames que en con un periodo de 1 fotograma y, aunque el error es 2.67 veces mayor que el error de referencia y esto, a priori, nos podría parecer mucho, comparado con el error obtenido en el resto de configuraciones no lo es tanto. Además, la proporción del error respecto a la mejora es tan sólo 1.1, lo que es prácticamente igual a la proporción error/mejora de la Prueba 1.

7.4. Comparación de Intervalos Superiores a 1

La lectura de imágenes del dron la haremos de manera asíncrona para asegurarnos de que siempre estamos analizando la imagen más reciente y poder así reaccionar correctamente a la situación. Nuestro dron en cuestión (Bebop 2) tiene una frecuencia de muestreo y envío de imágenes de 30 fps y, como hemos visto antes, con un periodo de detección cada 3 fotogramas y una lectura síncrona del vídeo conseguimos procesar 23 imágenes por segundo. Con esta pequeña diferencia de fps , estimamos que el máximo de frames que perderemos al realizar la lectura asíncrona será 2 o 3. Por ello los siguientes experimentos muestran los resultados de ejecución con intervalos de lectura de 2 y 3 frames.

7.5. Intervalo: 2 fotogramas

Prueba 1

- **Mean time:** 0.109478187455
- **Max track:** 160
- **FPS:** 8.56456529636
- **Frames Totales:** 449
- **Tiempo total:** 52.4253110886
- **Intervalo:** 2
- **Periodo:** 1

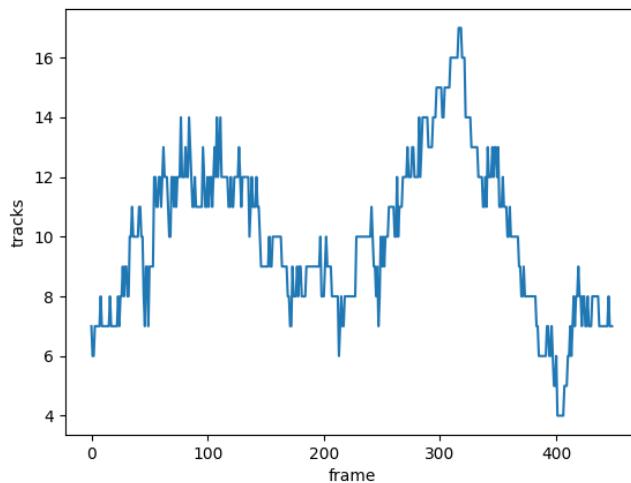


Figura 42: Número de tracks detectados por frame

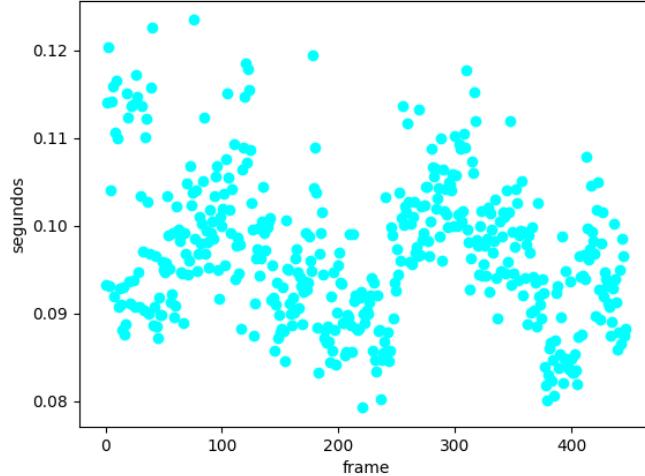


Figura 43: Tiempo de procesamiento requerido por frame

Lo primero a mencionar es la consecuencia más obvia que tiene aplicar un intervalo de lectura superior a 1 y es que el número de frames procesados ha disminuido. Como el intervalo que hemos aplicado es igual a 2, hemos procesado exactamente la mitad de frames (449 frente a los 899 totales).

Otra característica interesante es el número de *fps* conseguidos. Conseguimos incluso menos imágenes por segundo que con un periodo e intervalo de 1 frame pero procesamos el vídeo al doble de velocidad ya que nos saltamos el procesamiento de uno de cada dos fotogramas. Los valores del intervalo y el periodo están relacionados:

Intervalo	Periodo	FPS	Tiempo de procesamiento medio por frame	Tiempo Procesamiento
1	2	16.93	0.1094	53.0870
2	1	8.56	0.0548	52.4253

Cuadro 11: Comparativa Intervalo vs Periodo

Aunque en el primer caso obtenemos el doble de imágenes por segundo, vemos que el tiempo total de ejecución en ambos casos es muy parecido (53.087 segundos para el primer caso y 52.425 segundos para el segundo). Esto es porque aunque procesamos los frames a la mitad de velocidad cuando tenemos un periodo de 1 frame, leemos el vídeo dos veces más rápido al tener un intervalo de dos.

El máximo de trazados por imagen es el más alto hasta ahora, superando los 16 trazados en su pico más alto. Esto es debido a que algunos trazados se mantienen activos más tiempo del normal porque no han seguido una transición fluida de su objetivo al saltarnos fotogramas. A pesar de esto,

que haya mayor número de trazados por frame es también debido a que utilizamos un periodo de detección igual a 1, y esto nos permite llevar un seguimiento de muchas más personas en escena.



Figura 44: Número de tracks detectados. Intervalo:2 Periodo: 1

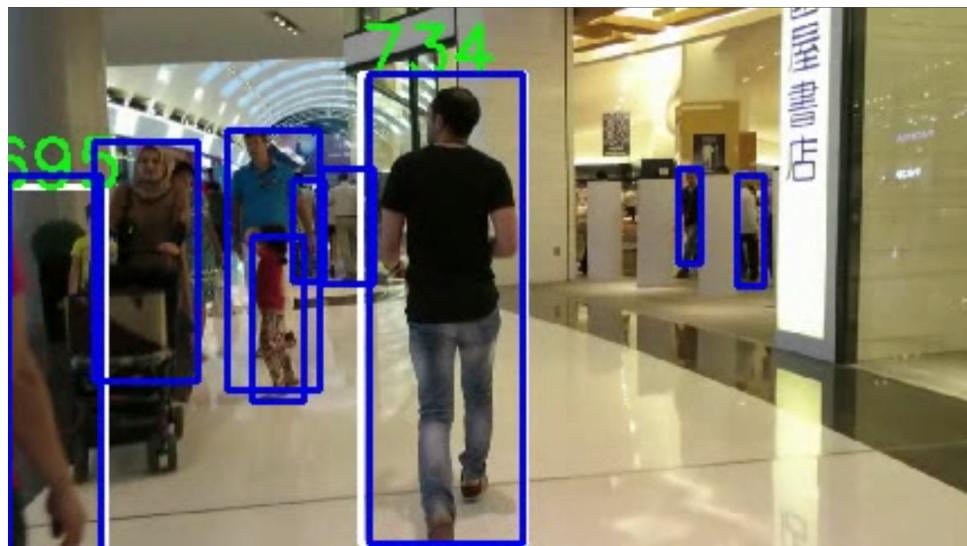


Figura 45: Número de tracks detectados. Intervalo:1 Periodo: 2

Vemos que aunque el número de detecciones es el mismo (*Bounding Boxes* azules) el número de *tracks* (*Bounding Boxes* blancos) es mucho mayor cuando tenemos un periodo de detección de 1 frame. Esto ocurre para todos los intervalos, como decimos, el único factor influyente es aumentar el periodo de detección.

Comparativa de pruebas Intervalo: 2

Como en la sección anterior, vamos a comparar los resultados obtenidos con un intervalo de lectura igual a 2, junto a distintas configuraciones de periodos de detección, para ver qué combinación es la mejor. Como referencia tendremos la ejecución realizada con periodo de detección igual a 1 ya que, como hemos visto en las figuras 44 y 45, es la ejecución que mejor resultado muestra a la hora de asignar trazados a personas en escena.

Periodo	FPS	Nº Tracks	Mejora (FPS / 8.56)	Error (Nº Tracks / 160)	Error / Mejora
1	8.5645	160	1	1	1
2	15.0613	797	1.76	5	2.84
3	19.3285	499	2.26	3.12	1.4
4	22.3785	385	2.61	2.4	0.92
5	18.1146	205	2.11	1.3	0.62
6	19.5321	566	2.28	3.53	1.55

Cuadro 12: Resultados de ejecución en MOT17_12

Constantes: Intervalo=2 Resolución:426x240

Nos encontramos dos resultados cuya proporción de Error/Mejora está en el intervalo [0-1). Esto implica que nos aportan mayor mejora que error. Así pues, podemos decir que el periodo de detección más adecuado para un intervalo de 2 fotogramas es 5, ya que, a partir de él, la proporción error/mejora vuelve a incrementar.

7.6. Intervalo: 3 fotogramas

Prueba 1

- **Mean time:** 0.130514128152
- **Max track:** 140
- **FPS:** 7.15106310074
- **Frames Totales:** 299
- **Tiempo total:** 41.8119649887
- **Intervalo:** 3
- **Periodo:** 1

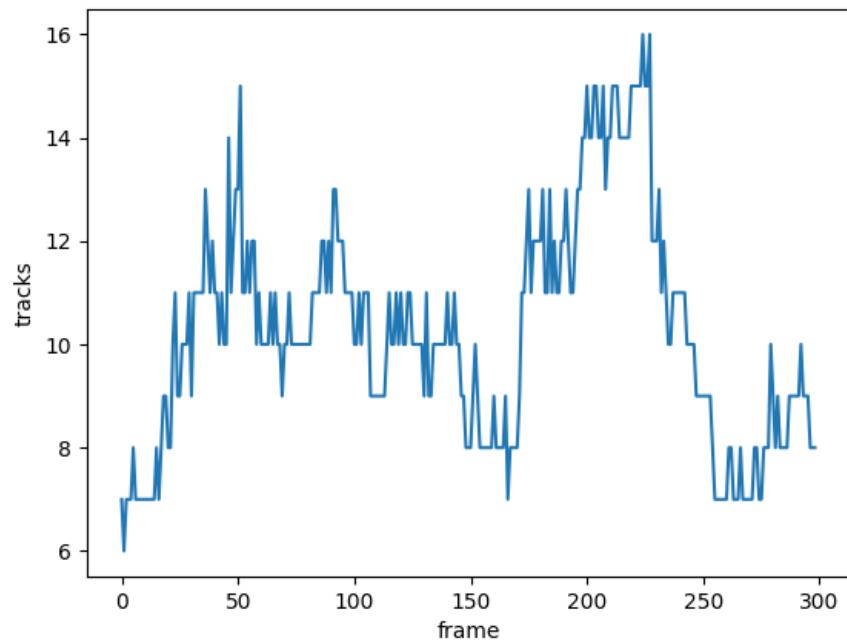


Figura 46: Número de tracks detectados por frame

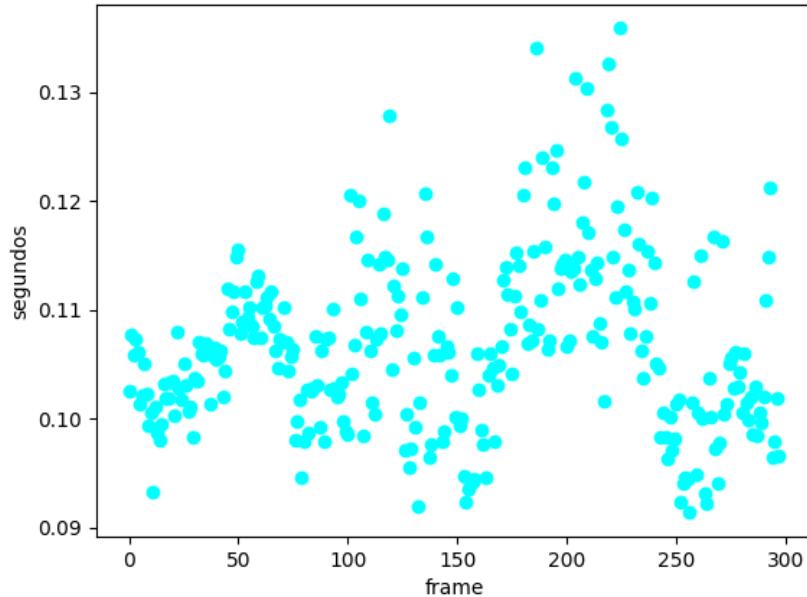


Figura 47: Tiempo de procesamiento requerido por frame

Aunque no lo mencionamos en las pruebas anteriores, vemos que la relación entre el número de *tracks* calculados por frame y el tiempo de procesamiento, siguen estando estrechamente relacionados aunque aumentemos el valor del intervalo de lectura de fotogramas.

Como hicimos con el intervalo de 2 frames, lo primero que mencionaremos es que el número de frames procesados ha vuelto a disminuir al aplicar un intervalo mayor. Esta vez hemos procesado un tercio de frames (299 frente a los 899 totales).

Como antes, podemos volver a ver la relación entre intervalo y periodo comparando las siguientes ejecuciones:

Intervalo	Periodo	FPS	Tiempo de procesamiento medio por frame	Tiempo Procesamiento
1	3	23.40	0.04478	38.4049
3	1	7.22	0.12906	41.3844

Cuadro 14: Comparativa Intervalo vs Periodo

La relación entre los *fps* es ahora de 3 a 1 debido al periodo de detección cada 3 fotogramas de la ejecución de la primera fila. Pero, aún siendo el procesamiento medio por frame cerca de 3 veces más rápido, el tiempo total es prácticamente igual debido a la lectura en intervalos de 3 fotogramas por parte de la ejecución de la segunda fila.

El pico de trazados también se muestra más alto de lo que lo hace en la ejecución de referencia de intervalo y periodo de 1 frame y es por los mismos motivos explicados anteriormente: debido a que la secuencia de fotogramas no es fluida puede haber trazados o *tracks* que perduren en el tiempo buscando una figura que ya no está en escena.

Comparativa de pruebas Intervalo: 3

En las dos comparativas anteriores mostraremos los resultados de las ejecuciones en una tabla donde la primera fila será la ejecución de referencia por tener el periodo de detección de 1 frame y ser por tanto la más precisa en cuanto a los trazados calculados.

Periodo	FPS	Nº Tracks	Mejora (FPS / 7.22)	Error (Nº Tracks / 140)	Error / Mejora
1	7.2249	140	1	1	1
2	11.3784	494	1.58	3.5	2.23
3	14.5387	353	2.01	2.52	1.25
4	18.81	268	2.6	1.91	0.74
5	15.6862	124	2.17	0.9	0.41
6	16.8406	353	2.32	2.52	1.1

Cuadro 15: Resultados de ejecución en MOT17_12

Constantes: Intervalo=3 Resolución:426x240

Como antes, nos encontramos dos resultados cuya proporción de Error / Mejora está en el intervalo [0-1) y por lo tanto nos aportan mayor mejora que error. De estas dos, hay una ejecución en específico que nos aporta menos tracks que la ejecución de referencia por lo que podríamos decir que no sufre errores, de hecho diríamos que mejora la primera ejecución, pero en este caso no sería tan acertada esta afirmación. La primera ejecución ya presenta menos tracks que la ejecución de referencia de la Prueba 1 (intervalo y periodo de 1 frame) lo que supone menos precisión respecto al seguimiento de personas. Esta ejecución con periodo de detección cada 5 fotogramas presenta menos trazados todavía, por lo que sería menos precisa aún. Sin embargo, como todo este estudio va dirigido a la ejecución del sistema de videovigilancia en una infraestructura crítica, donde el tránsito de personas es muy escaso o nulo, el hecho de poder aplicar seguimiento hasta a 124 figuras es más que suficiente. Por ello, podemos declarar la configuración de periodo de detección igual a 5 frames como la más adecuada para un intervalo de 3 fotogramas.

Comparativa de Intervalos

Intervalo	Periodo	FPS	Nº Tracks	Tiempo de Ejecución
1	3	23.0309	489	39.0345
2	5	18.1146	205	24.7866
3	5	15.6862	124	19.0612

Cuadro 17: Comparativa de ejecuciones con distintos intervalos de lectura

Como hemos dicho al inicio de la comparativa con intervalos superiores a 1 frame, el dron transmite 30 imágenes por segundo. Con un la primera opción de parámetros, procesamos 23 imágenes por segundo lo cual implica perder 7 frames de los 30 mandados por el dron (si es que no hubiese problemas de conexión y los recibíramos todos). Con cualquier otra opción perderíamos muchos más de 7 frames. Perderíamos la información de 15 frames en el caso de usar un intervalo de 2 fotogramas y 20 si el intervalo fuese de 3. Por esto, decidiremos aplicar un intervalo dinámico o asíncrono, con un periodo de detección cada 3 frames ya que, aunque sea asíncrono, conseguiremos leer la mayoría de ellos secuencialmente (intervalo de lectura=1).

Conclusiones

Hemos visto que los distintos parámetros que podemos ajustar en la ejecución modifican de manera diferente los resultados:

- **Resolución:** Afecta de manera significativa a los *fps*. A menor resolución mayor cantidad de cuadros por segundo obtendremos. También afecta al número de tracks encontrados en escena aunque de una forma apenas notable.
- **Intervalo:** Influye en la cantidad de tracks detectados debido a que, al saltarnos fotogramas, perdemos información. Y reduce el tiempo de procesamiento total por la misma razón.
- **Periodo:** Influye mucho en la consistencia de los trazos (*tracks*) calculados ya que funciona como una realimentación para los atributos del identificador. También influye en el tiempo de procesamiento al evitar realizar detección de figuras en escena en todos los fotogramas.

Recordamos que todas las pruebas junto con los resultados, vídeos y gráficas obtenidas se encuentran en la carpeta de MEGA [21] para cualquier consulta y/o aclaración.

7.6.1. Consistencia del Tracker

Definiendo el periodo de detección por defecto

Como hemos visto en el apartado de la oclusión, el detector se desenvuelve muy bien incluso a una resolución tan baja como es 426x240. Será esta resolución la que usaremos para realizar las siguientes pruebas además de un intervalo de lectura de 1 frame y un periodo de detección cada 3 frames como hemos concluido en las experimentaciones anteriores. Vamos a evaluar la consistencia del algoritmo de seguimiento (*tracker*) con el benchmark MOT17_05:

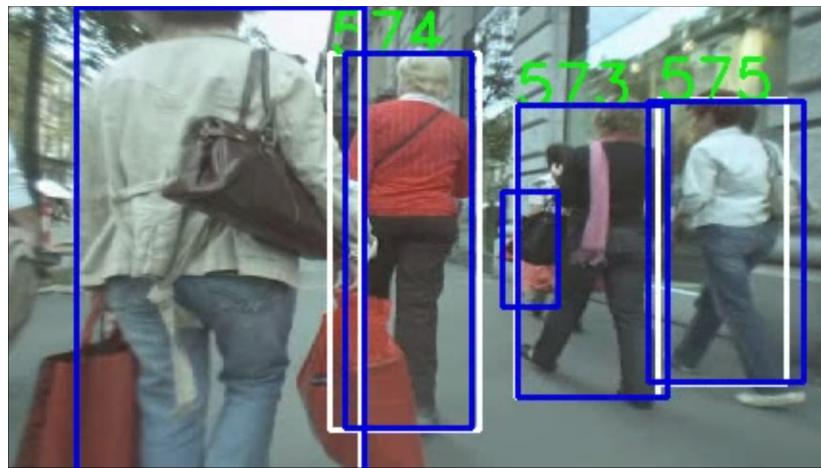


Figura 48: MOT17_05 secuencia:0



Figura 49: MOT17_05 secuencia:1



Figura 50: MOT17_05 secuencia:2



Figura 51: MOT17_05 secuencia:3

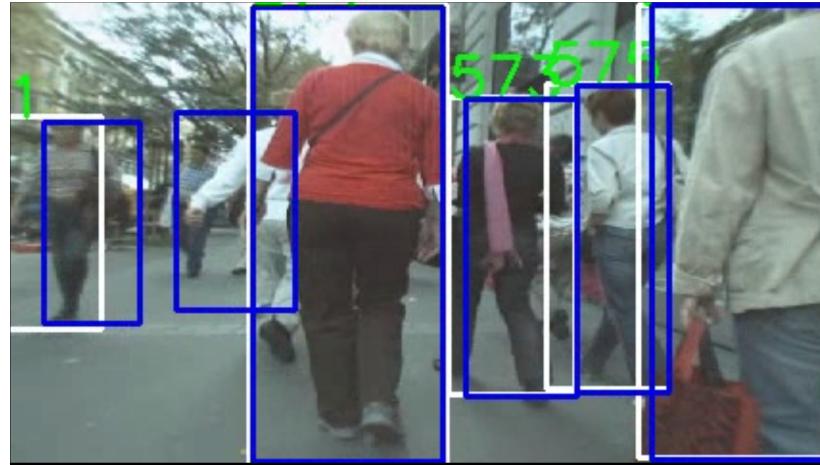


Figura 52: MOT17_05 secuencia:4

La consistencia del tracker se demuestra cuando tras perder el track de una persona es capaz de reasignar el identificador a la misma figura cuando reaparece en escena.

En la sucesión de imágenes de arriba vemos como se mantiene la consistencia.

En la primera imagen aparecen tres personas con identificadores 574, 573 y 575.

En las tres siguientes, otra persona se cruza delante de la cámara y las tapa por completo perdiendo así su detección, pero los tracks siguen activos buscando figuras que encajen con su descripción.

En las figuras 50 y 52, las tres personas vuelven a aparecer en escena y el algoritmo es capaz de identificar que se tratan de las mismas figuras que antes y les reasigna el mismo ID.

Esta situación grabada desde un dron sería, casi con total seguridad, más sencilla para el algoritmo de seguimiento. La escena mostraría un plano picado de la zona y, por lo tanto, las personas se mostrarían más separadas entre sí. No tendríamos tantas situaciones de ocultación como sucede en la secuencia superior y obtendríamos un rango de visión mucho más amplio. La red neuronal tendría que ser entrenada para detectar personas desde planos picados, ya que el conjunto de datos COCO entrena la red para reconocer personas que se encuentren de pie y desde un punto de vista que permita ver el cuerpo entero pero no vistas desde arriba. Como en nuestro caso, por limitaciones de distancia de conexión no podemos elevar el dron hasta grandes alturas, las imágenes tomadas desde él muestran personas en planos reconocibles por el detector y no ha sido necesario volver a entrenar el detector YOLOv3 [29].

7.7. Pruebas con el Dron

7.7.1. Vuelo con app

- Modo Manual:

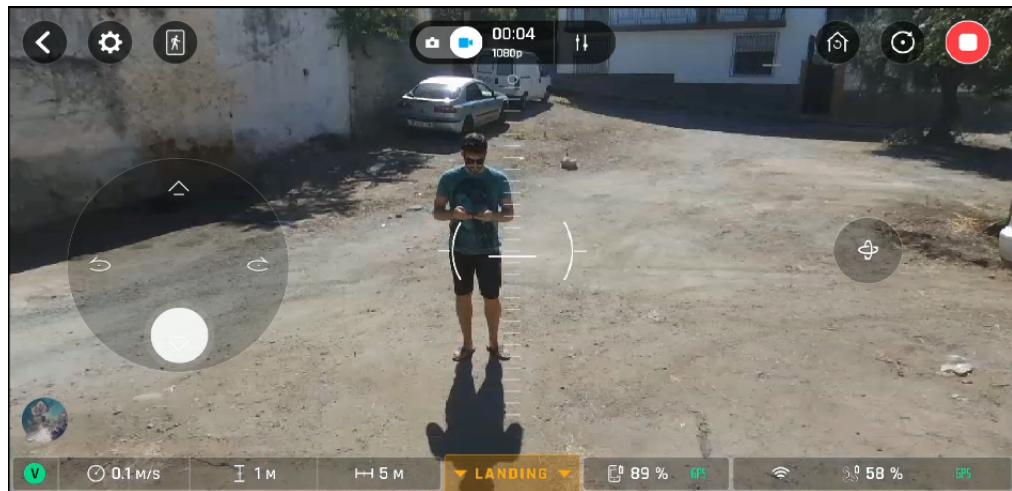


Figura 53: Interfaz HUD (Head-Up Display) del modo pilotaje manual de la aplicación Free Flight Pro

En pantalla aparece gran cantidad de información: velocidad actual de movimiento, altura a la que vuela, tiempo de grabación e, incluso, porcentajes de batería tanto del *smartphone* o *tablet* como del propio dron.

También aparecen todos los controles con los que podemos interactuar con el dron. Los dos principales son la cruceta/*joystick* de la izquierda que permite movimientos en el eje Y (ascenso y descenso) y rotar en ambas direcciones. A la derecha se encuentra el control de movimiento en los ejes X y Z que utiliza el giroscopio del dispositivo con el que nos conectamos al dron para recibir las órdenes. Si inclinamos el móvil hacia delante el dron avanzará, si lo inclinamos hacia atrás el dron retrocederá, e igual sucede hacia los lados.

En la parte superior de la pantalla, en el centro, se encuentran los controles para cambiar entre modo fotografía y vídeo. También arriba pero a la derecha se encuentran comandos de movimiento autónomo que permiten la vuelta del dron al punto de partida, y realizar un barrido circular de la zona. También en esta esquina está el control para iniciar o detener la grabación de vídeo. Por último, en la esquina contraria, encontramos un acceso a los ajustes del dron, y otro acceso al modo de tracking. Este modo lo describimos a continuación.

■ Modo Automático:



Figura 54: Interfaz HUD (Head-Up Display) del modo pilotaje automático de la aplicación Free Flight Pro

En este modo automático aparecen dos controles nuevos en pantalla abajo a la derecha. Nos permite bloquear la interacción con los controles para no interferir en el vuelo de manera no intencionada y también superponer en pantalla los controles del control manual para tomar el control del dron en cualquier momento.

En esta pantalla podemos seleccionar con un recuadro un objeto al que perseguir. Este recuadro lo tiene que dibujar manualmente el usuario. La aplicación extrae las características del área que hay dentro del rectángulo y *trackea* la figura por la escena. Esto nos permite seguir a cualquier tipo de objeto (personas, animales, vehículos).

Una vez seleccionada la figura a seguir el dron se mantendrá estático y seguirá al objetivo tan solo rotando. Para comenzar una persecución activa debemos pulsar sobre la opción *FOLLOW* que aparece en el centro de la pantalla, abajo. Ahora el dron pasa a perseguirnos si nos alejamos y a alejarse de nosotros si nos acercamos para mantener siempre cierta distancia. Si nos movemos en el plano horizontal, el dron se moverá junto a nosotros horizontalmente en vez de rotar para centrarnos en su visión y seguirnos de frente.

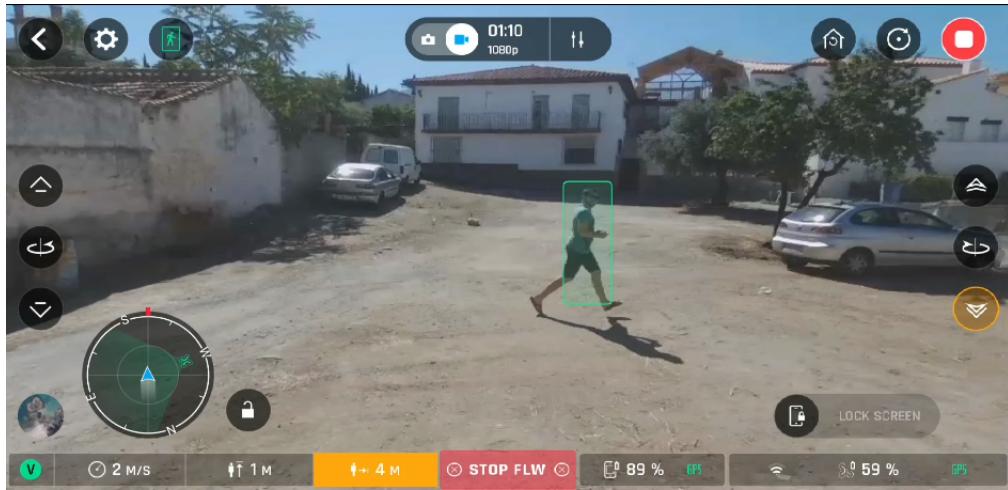


Figura 55: Dron siguiendo al objetivo de manera activa

Con todas estas características, ¿por qué querríamos desarrollar otra aplicación, que a priori, realiza la misma función? El objetivo de la aplicación creada, es aportar modularidad e inteligencia al sistema. Con este trabajo de fin de grado, hemos realizado un sistema de seguimiento al que podemos acoplar más de un dron, podemos incorporar imagen proveniente de cámaras estáticas, los objetos detectados son reconocidos y clasificados por el sistema de manera que sabemos qué es lo que estamos siguiendo. El algoritmo de detección cuenta con una gran lista de objetos reconocibles en la que, además de personas, encontramos, coches, motocicletas, camiones, gatos, perros, vacas, y un largo etcétera. También podemos entrenar la red neuronal para que reconozca cualquier objeto que nos interese. Además realizamos un *multitracking* de todos los objetos de la escena que nos permite cambiar entre objetivos de manera rápida, y por supuesto existe la opción de expandir la aplicación y dotar al dron de un comportamiento más complejo que tenga en cuenta más variables del entorno. Por ejemplo, podríamos incorporar un software de detección de profundidad de imagen 2D para evitar así chocar con obstáculos e incluso poder evitarlos.

Por todo esto creo que la aplicación desarrollada tiene mucho potencial y supone una muy buena base de la que partir para realizar proyectos verdaderamente complejos con grandes capacidades.

7.7.2. Ejecución en Equipo Portátil

La experimentación con el equipo portátil fue de corta duración. La eficiencia es ínfima y no proporciona una experiencia fluida.

Figura 56: Evolución de *fps* y número de tracks a lo largo de los frames

Durante la ejecución no conseguimos alcanzar los 0.8 *fps* y cuando aparece una persona en escena y se calcula su track, los cuadros por segundo caen en picado hasta los 0.6 e intentan estabilizarse en torno a los 0.7. Estos valores se deben a que la ejecución se realiza en la CPU y su procesador gráfico integrado (el equipo no dispone de tarjeta gráfica dedicada) y estos no disponen de la potencia para realizar el procesamiento requerido por el sistema.

La siguiente imagen 57 muestra el estado del equipo durante la ejecución de la aplicación en la que vemos que los cuatro núcleos del procesador y la memoria RAM están trabajando al 100 % de su capacidad y aún así solo logramos obtener los resultados vistos en la gráfica superior 56.

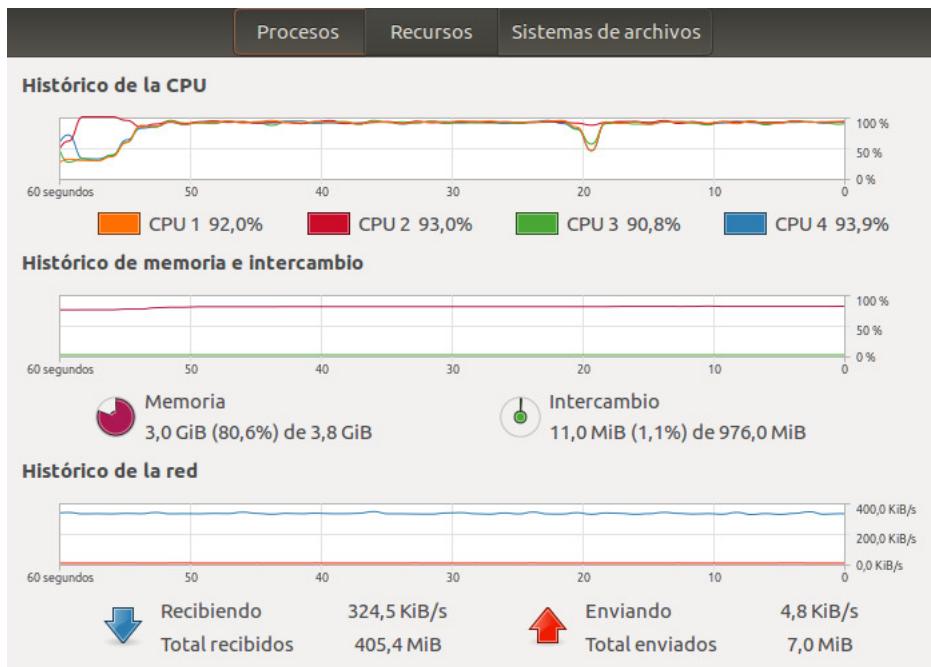


Figura 57: Estado del equipo portátil durante la ejecución de la aplicación

Estos resultados los obtenemos tan sólo iniciando el módulo de visión por computador. Si iniciásemos el módulo de movimiento autónomo, que supone la creación de una nueva hebra, los resultados serían incluso peores.

7.7.3. Vuelo automático

Como hemos dicho en la sección de ejecución con el equipo portátil, el hecho de iniciar o no el vuelo automático, repercute en la fluidez de la ejecución ya que crea una nueva hebra. Esto lo podemos ver en el equipo de sobremesa comparando los resultados obtenidos en vuelo manual y automático.

Figura 58: *fps* en modo manual

Figura 59: *fps* en modo automático

Se aprecia en el gráfico del modo de vuelo manual 58 que los *fps* son muy estables y rondan los 12 *fps*, específicamente tiene una media de 12.1598130319 *fps* durante toda la ejecución.

En cambio en el modo automático ??, vemos que a partir del track 75 (aproximadamente), que es cuando iniciamos el modo automático, los *fps* descienden de 12.5 a, aproximadamente, 11. Los *fps* medios obtenidos, teniendo en cuenta el inicio en modo manual, son 10.950283759.

Estos casi 11 *fps* nos permiten obtener buenos resultados durante la ejecución aunque, por supuesto, sería deseable contar con mayor cantidad de fotogramas. Estos dos gráficos corresponden a pruebas estáticas, es decir, el dron se encuentra parado y no le enviamos comandos de movimiento pero sí activamos la nueva hebra que se encarga del movimiento autónomo.

A continuación vamos a ver los resultados de ejecutar el sistema al completo. Incorporamos la imagen de una cámara estática junto al vídeo proporcionado por el dron. En primer lugar, fijamos un objetivo en la cámara fija, cuando este objetivo salga de plano y el track se desactive, se manda una orden de despegue al dron. Cuando el dron ya está en el aire seleccionamos un identificador de los captados por esta entrada de vídeo y comienza la persecución del objetivo indicado.

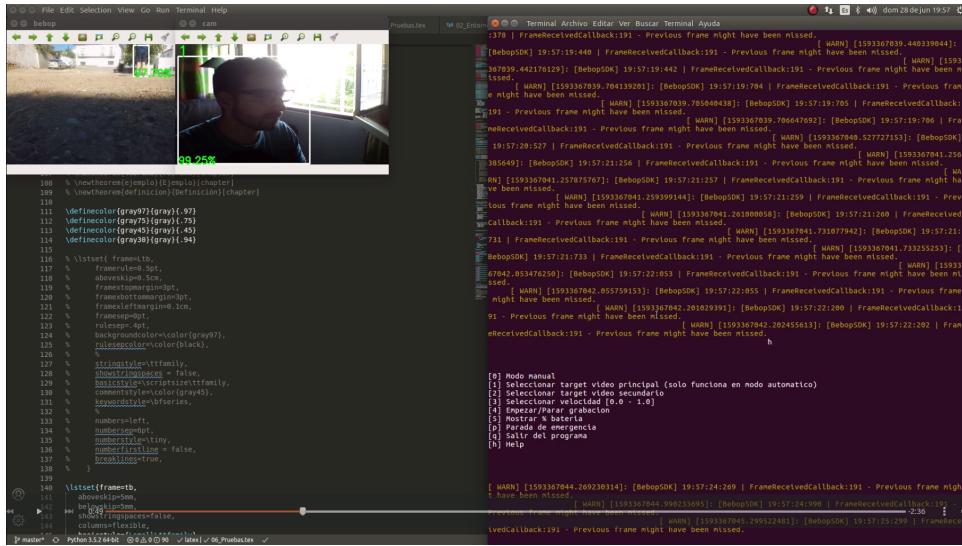


Figura 60: Inicio del sistema

En esta captura vemos que al iniciar el sistema contamos con la visión de la cámara fija en la que aparece una figura trackeada. También vemos la imagen del dron que se encuentra reposando en el suelo y, a la derecha, la ejecución de la aplicación en la terminal. Los mensajes de warning son debidos a pérdida de fotogramas entre el dron y el servidor. Recordemos que estos dos equipos están separados alrededor de unos 25 metros y además hay obstáculos que interfieren en la señal.

```
[1] Seleccionar target video principal (solo funciona en modo automatico)
[2] Seleccionar target video secundario
[3] Seleccionar velocidad [0.0 - 1.0]
[4] Empezar/Parar grabacion
[5] Mostrar % bateria
[6] Parada de emergencia
[7] Salir del programa
[h] Help

[ WARN] [1593367053.047605485]: [BebopSDK] 19:57:33:047 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367053.149095082]: [BebopSDK] 19:57:33:149 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367053.690150678]: [BebopSDK] 19:57:33:690 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367053.691264180]: [BebopSDK] 19:57:33:691 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367053.727031127]: [BebopSDK] 19:57:33:726 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367053.192610318]: [BebopSDK] 19:57:35:192 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367055.195537223]: [BebopSDK] 19:57:35:195 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367055.238027054]: [BebopSDK] 19:57:35:237 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367055.451501018]: [BebopSDK] 19:57:35:451 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367055.453817927]: [BebopSDK] 19:57:35:453 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367055.710246894]: [BebopSDK] 19:57:35:710 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367055.712119139]: [BebopSDK] 19:57:35:712 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367056.402799101]: [BebopSDK] 19:57:36:402 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367056.405123471]: [BebopSDK] 19:57:36:405 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367056.410029234]: [BebopSDK] 19:57:36:409 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367056.412623991]: [BebopSDK] 19:57:36:412 | FrameReceivedCallback:191 - Previous frame might have been missed.
2
'-1'Exit.
Select target:
[ WARN] [1593367056.609123536]: [BebopSDK] 19:57:36:609 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367056.611751325]: [BebopSDK] 19:57:36:611 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367057.638281453]: [BebopSDK] 19:57:37:638 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367057.639267505]: [BebopSDK] 19:57:37:639 | FrameReceivedCallback:191 - Previous frame might have been missed.
[ WARN] [1593367057.640361066]: [BebopSDK] 19:57:37:640 | FrameReceivedCallback:191 - Previous frame might have been missed.
1
```

Figura 61: Selección de ID en cámara fija

Si ampliamos la captura de pantalla superior 61, vemos que estamos seleccionando la opción del menú que nos permite indicar un objetivo a perseguir en la entrada de vídeo que nos proporciona la cámara fija. Seleccionamos el identificador 1 que es el único que aparece en pantalla.

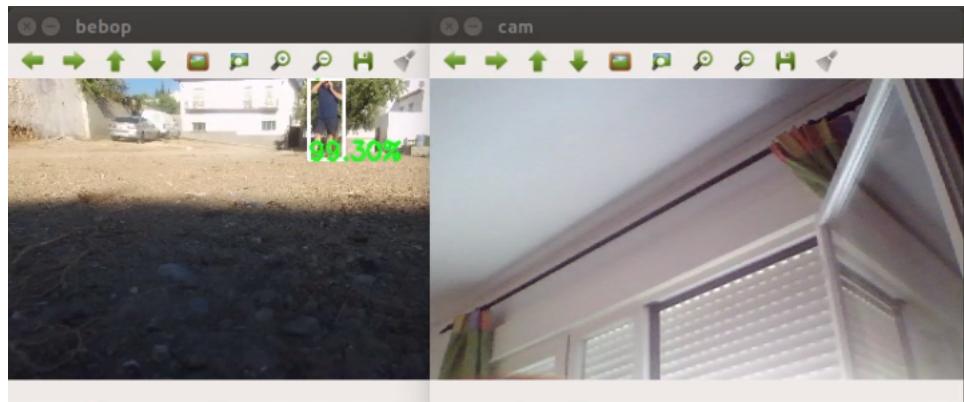


Figura 62: Salida de escena

El siguiente paso es simular que el objetivo marcado se sale de escena. En este caso movemos la cámara para que deje de ver el objetivo marcado anteriormente. Tras unos segundos en los que la figura no aparece en escena, su track se desactiva y se manda un comando al dron para que despegue.

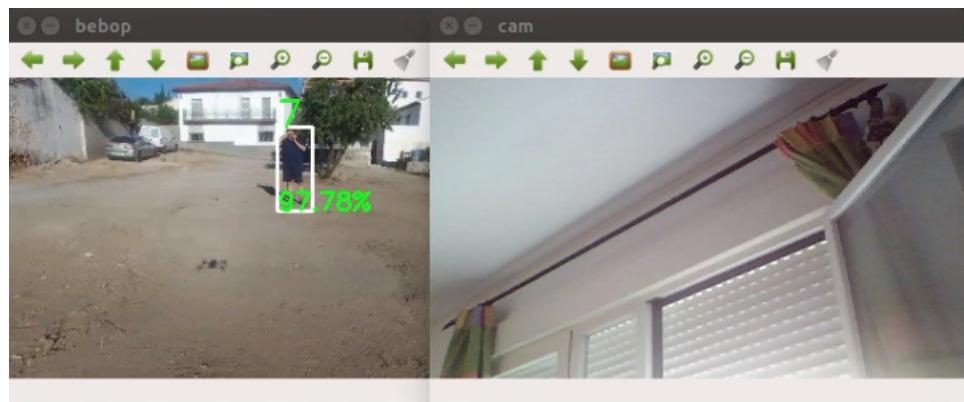


Figura 63: Despegue automático

Aquí podemos ver al dron ya en el aire pero aún estático. A continuación indicamos el ID del track que debe empezar a perseguir.



```

h

[0] Modo manual
[1] Seleccionar target video principal (solo funciona en modo automatico)
[2] Seleccionar target video secundario
[3] Seleccionar velocidad [0.0 - 1.0]
[4] Empezar/Parar grabacion
[5] Mostrar % bateria
[p] Parada de emergencia
[q] Salir del programa
[h] Help

1
'-1'Exit.
Select target:
7
Target Updated
■

```

Figura 64: Selección de objetivo en vídeo del dron

Seleccionamos la opción del menú para indicar el track que aparece en el vídeo del dron e introducimos el track 7. En este momento se actualiza el track al que debe perseguir y se crea la hebra que ejecuta el comportamiento reactivo.

Durante la ejecución ponemos a prueba la consistencia en la detección y el tracking situando el dron en situaciones adversas.



Figura 65: Detección a contra luz - Bebop

La captura ha sido tomada directamente del vídeo grabado a bordo del dron por eso no aparece el Bounding Box pero si observamos el vídeo capturado en la ejecución en servidor vemos que el objetivo sigue siendo detectado y '*trakeado*'.

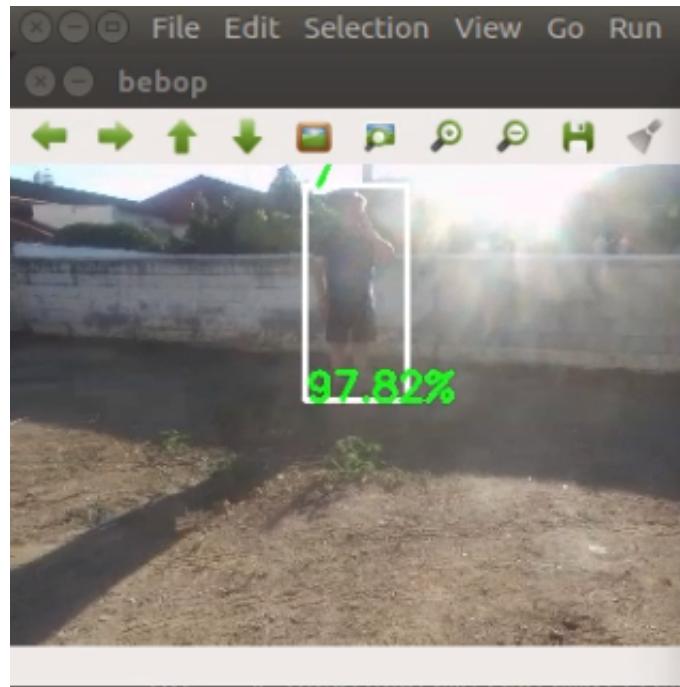


Figura 66: Detección a contra luz - Servidor

Otra situación compleja es llevar al objetivo a una zona oscura rodeada de mucha luz. Lo que hacemos es situar al dron en una escena con altos contrastes. Al igual que antes, la primera imagen corresponde con el vídeo a bordo del dron y la segunda a la captada en servidor.



Figura 67: Detección en alto contraste - Bebop

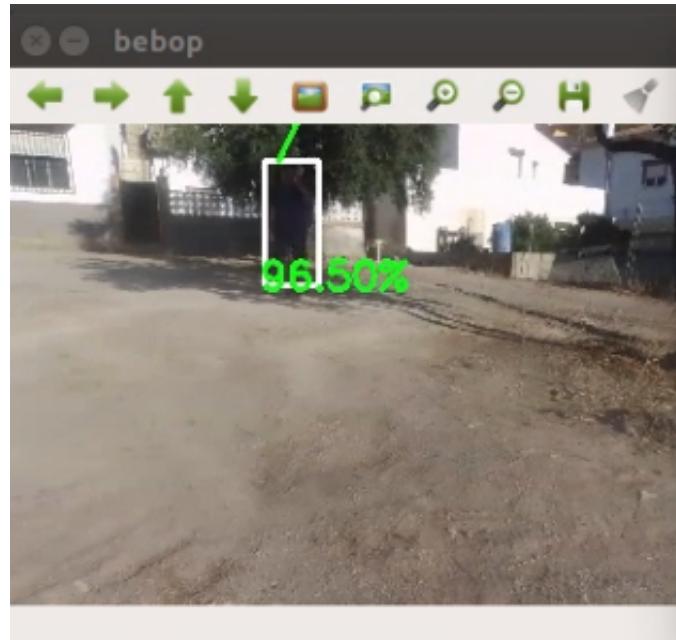


Figura 68: Detección en alto contraste - Servidor

En esta situación también se desenvuelve bien la aplicación.

Para ver realmente cómo funciona el sistema y ver todo el procedimiento de la ejecución realizada, hemos dejado en la carpeta de MEGA [21] unos vídeos que muestran toda la consecución de hechos de principio a fin.

Para finalizar vamos a mostrar los gráficos de la evolución de los *fps* y el número de track que aparecen en escena durante la ejecución.

Figura 69: Evolución en vídeo Bebop

Al principio de la figura vemos que el número de tracks es inestable y es porque se está transportando el dron hacia la zona de vuelo y, durante el trayecto, se realizan más detecciones pero durante el resto de la ejecución el número de tracks se mantiene constante en 1.

El decremento de *fps* a lo largo de la ejecución se debe a la pérdida de frames durante la transmisión como hemos comentado tras la figura 60. Por eso se producen picos de subida, que coinciden con los momentos en los que obtenemos una mejora de conexión y evitamos dicha pérdida de datos.

Aún con la pérdida de fotogramas, la media de *fps* se mantiene cerca de los números dados al inicio de la sección obteniendo 10.85 *fps* de media y rondando los 12.5 al principio de la ejecución, de hecho, alcanzando un pico de 13.72 *fps*.

Figura 70: Evolución en vídeo Cámara fija

Respecto a la cámara fija, el número de *fps* es relativamente constante y se mantiene en todo momento en torno a 12.5. En el subgrafo que marca el número de tracks, se aprecia que iniciamos la ejecución con una persona en escena y que, sobre el frame número 300, desaparece de ella. Es aquí cuando se manda al dron la orden de despegar porque hemos perdido el track de la persona que habíamos marcado como objetivo.

7.7.4. Otros experimentos para evaluar Características No Funcionales de Calidad

- **Ancho de banda:** Hemos medido el ancho de banda que consume comunicarnos con el dron desde el framework ROS. El *topic image_raw* por el que mandamos los mensajes tipo *Image* que contienen los frames del vídeo que capta el dron, ocupa un ancho de banda de 37.3MB/s. Y el *topic cmd_vel* por el que mandamos los comandos de movimiento, suponen 1.57KB/s de consumo de ancho de banda.
- **Consumo de batería:** Hemos comparado el consumo de batería al usar la aplicación móvil propietaria de *Parrot* y al usar la aplicación desarrollada en este proyecto. A la hora de medir el consumo de batería lo hemos hecho con el dron en reposo tan sólo haciendo uso del módulo

de visión por computador *trackeando* a una persona. Hemos quitado de la ecuación el hecho de volar el dron, ya que en los dos sistemas supone el mismo esfuerzo y, de hecho, puede haber variaciones debidas a ráfagas de viento ante las que el dron se tenga que estabilizar. Por ello, tan sólo hemos medido el consumo ejecutando la característica que realmente diferencia a los dos sistemas: su método de *tracking*.

Para hacer la medición, marcamos una figura a seguir y mantenemos la ejecución durante 15 minutos. Tras este tiempo los resultados fueron:

- **Sistema desarrollado durante el proyecto:** Empieza en un 98 % de batería y finaliza con 93 %.
- **Sistema propietario de Parrot:** Empieza con 91 % y acaba con 85 %.

La diferencia no es, ni mucho menos, significativa (5 % vs 6 %) aunque puede que si alargásemos la prueba, las distinciones fueran más notables. Aún si fuera el caso, no repercutiría mucho a la hora de decidir qué sistema usar, ya que las baterías del dron permiten vuelos de 25 minutos según el fabricante, lo cual nos dice que serán al rededor de 20 minutos reales con unas baterías nuevas.

8. Conclusiones y Futuras Mejoras

En este proyecto hemos estudiado y desarrollado un sistema de video vigilancia activo mediante la incorporación de drones que supone una solución a los problemas que sufren los sistemas tradicionales y que va especialmente enfocado a la supervisión de zonas o infraestructuras críticas debido a su carácter automático.

A continuación se definen los objetivos planteados inicialmente y el estado en el que se encuentran tras finalizar el proyecto.

En primer lugar, se estableció el objetivo de estudiar el estado del arte de los sistemas de video vigilancia y del uso dado a los drones. Tras este estudio, pusimos de manifiesto la amplia gama de sectores e industrias en las que se utilizan los drones, y las diferentes tareas a las que están destinados en cada una de ellas. Respecto a los sistemas de vigilancia actuales, se presentan los problemas socioeconómicos que conlleva actualmente la video vigilancia con personal humano y más aún en infraestructuras críticas.

Se propuso, en segundo lugar, aprender las funcionalidades y herramientas que concede el framework ROS y que nos permiten integrar módulos de naturaleza y comportamiento heterogéneo en un mismo sistema dirigido a trabajar con robots. Durante la realización del proyecto hemos aprendido a incorporar paquetes de terceros en el sistema, hemos creado un paquete propio, aprendido a trabajar con su sistema de suscripciones y publicaciones en *topics*, hemos aprendido cómo es su estructura de directorios, los comandos más comunes con los que trabajar en el framework, a crear ficheros de ejecución complejos y, debido a los diversos problemas a la hora crear una instalación sólida, hemos estudiado distintas versiones y distribuciones del producto como ROS Melodic o ROS2.

En tercer lugar, nos propusimos estudiar el estado del arte de algoritmos de detección y tracking de personas y valorar su capacidad de funcionamiento en un sistema de video vigilancia. Las mejores opciones encontradas pertenecían al ámbito de la Inteligencia Artificial y así, no sólo estudiamos los métodos más actuales en la labor de identificación y seguimiento de personas, sino que, además, los implementamos en nuestro proyecto dotando al mismo de características igual de potentes como llamativas. Se ha implementado el algoritmo DeepSORT junto a la CNN (red neuronal convolucional) YOLOv3 y se ha mostrado su eficacia junto con los costes computacionales que supone y las limitaciones que conlleva. Estas limitaciones nos obligaron a ejecutar la aplicación en un equipo que contase con una tarjeta gráfica NVIDIA dedicada para trabajar con los drivers CUDA.

Nos propusimos un cuarto objetivo poco ambicioso, pero a su vez muy necesario, útil y realista: la elaboración de una funcionalidad que nos permitiese controlar el dron de manera manual. Este objetivo, que comparado con la meta final del proyecto, no parece importante, es un buen paso intermedio que nos ha permitido conocer la integración de ROS con python mediante bibliotecas, y crear un mecanismo de seguridad en el sistema por el que podemos tomar el control total del dron si fuera necesario.

Como quinto objetivo se fijó intentar dotar el dron de un comportamiento reactivo por el cual fuese capaz de perseguir a un objetivo indicado. A través de las características obtenidas por los algoritmos de detección y tracking somos capaces de focalizar el seguimiento en una única persona de entre una multitud, y adaptar los movimientos del dron según aparezca esa persona representada en escena. Esta funcionalidad se ve altamente afectada por el número de *fps* que consiga procesar nuestro algoritmo de tracking, por lo que para obtener buenos resultados, debemos disponer de un buen equipo hardware.

El sexto objetivo trata de dar un enfoque más genérico al proyecto y hacerlo multipropósito. Se pretende realizar un sistema configurable de manera que podamos introducirlo en la mayor cantidad de sectores e industrias diferentes posibles. Esta capacidad la hemos obtenido gracias a incorporar YOLOv3 como detector del sistema que además ha sido entrenado con la base de datos COCO. De esta manera, no es sólo capaz de identificar personas, también gran cantidad de animales, vehículos y objetos varios. Sin retocar demasiado el sistema actual, también podríamos orientarlo al mundo de cine para grabar persecuciones o tomas aéreas de paisajes. Si decidimos, por ejemplo realizar detección y seguimiento de animales de granja, podríamos usarlo, además de para vigilar los animales, para realizar la función de pastor o guía. Si reentrenamos la red neuronal para detectar ciertos tipos de señales arbitrariamente seleccionadas, podríamos inferir en el sector de la agricultura y recorrer grandes campos de cultivos señalizados con estas balizas para plantar semillas, echar pesticida o, de nuevo, llevar un control de la zona. Son muchas las aplicaciones que podemos dar al sistema ya que, además de la libertad que nos confiere el detector, el módulo de comportamiento es fácilmente desacoplable y podríamos diseñar otro nuevo o modificar el existente para adaptarlo a nuevas funcionalidades.

El séptimo objetivo es contribuir a la comunidad de software libre, más específicamente, a la comunidad orientada a la robótica, liberando el código desarrollado y alojarlo en GitHub. Esto se ha hecho tal cual se prometió y podemos encontrar el proyecto subido en el siguiente enlace [20].

Por último, gracias a mis tutores del trabajo de fin de grado y a los miembros del grupo de investigación de FITOPTIVIS que me han ayudado con el proyecto, he aprendido las herramientas de planificación y comunicación *Trello* y *Slack*, las cuales consiguen hacer estas tareas más sencillas y además permiten ver mi planificación y avances a mis supervisores del proyecto.

Como futuras mejoras se propone mejorar el equipo hardware sobre el que se ejecuta el algoritmo de *tracking*, ya sea adquiriendo mejor hardware local o implementar la ejecución del código en un servidor externo.

También podemos incorporar nuevas características al sistema de visión como un software que extraiga un mapa de profundidad a partir de una imagen 2D para así poder evitar o sortear obstáculos con el dron. También podríamos implementar un sistema de posicionamiento 3D con la ayuda de varias cámaras estáticas de manera que cuando el sujeto objetivo abandonase la escena tendríamos unas coordenadas espaciales a las que poder enviar el dron para seguir buscando el objetivo.

Por supuesto debemos estar atentos a los avances en el estado del arte de cualquier aspecto de rendimiento y eficiencia considerados en el proyecto. Dado que se ha desarrollado de manera modular, no es difícil actualizar cualquiera de los módulos del proyecto sin afectar al funcionamiento del resto del sistema.

Referencias

- [1] Directiva europea: 2008/114/CE - Infraestructuras Críticas. <https://eur-lex.europa.eu/legal-content/ES/TXT/?uri=celex:32008L0114>.
- [2] Documentación Bebop Autonomy. <https://bebop-autonomy.readthedocs.io/en/latest/index.html>.
- [3] ROS. <https://www.ros.org/>.
- [4] J. Redmon and A. Farhadi, "Yolov3: An incremental improvement," *CoRR*, vol. abs/1804.02767, 2018. <https://pjreddie.com/media/files/papers/YOL0v3.pdf>.
- [5] DeepSORT. <https://nanonets.com/blog/object-tracking-deepsort/>.
- [6] Drones en el Cine. <https://dronelife.com/2018/08/07/drones-are-becoming-a-filmmakers-tool/>.
- [7] Servicio de Paquetería con Drones - UPS. <https://www.ups.com/us/es/services/knowledge-center/article.page?kid=cd18bdc2>.
- [8] Servicio de Paquetería con Drones - Amazon. <https://www.amazon.com/Amazon-Prime-Air/b?ie=UTF8&node=8037720011>.
- [9] Servicio de Paquetería mediante el uso de Drones - Correos. <http://www.fesofi.es/noticias/correos-utilizara-drones-para-repartir-en-zonas-dificiles/>.
- [10] Aplicaciones de Drones Urbanísticas - Universidad de Córdoba. <http://drones.uv.es/aplicaciones-de-drones-urbanisticas/>.
- [11] Drones DGT. <http://revista.dgt.es/es/multimedia/infografia/2019/04ABRIL/0417-Drones.shtml#.XvtoMpZS9hF>.
- [12] Monitorización y optimización de tierras con drones y fotogrametría aérea para aplicaciones de precisión en agricultura - Universidad Politécnica de Valencia. <https://riunet.upv.es/handle/10251/86353>.
- [13] Z. Zaheer, A. Usmani, E. Khan, and M. A. Qadeer, "Aerial surveillance system using UAV," in *Thirteenth International Conference on Wireless and Optical Communications Networks, WOCN 2016, Hyderabad, Telangana State, India, July 21-23, 2016*, pp. 1–7, IEEE, 2016. <https://doi.org/10.1109/WOCN.2016.7759885>.
- [14] CB-Insights. <https://www.cbinsights.com/research/drone-impact-society-uav/>.

- [15] Divya Joshi - Business Insider. <https://www.businessinsider.com/drone-technology-uses-applications?IR=T>.
- [16] Federal Aviation Administration. <https://www.faa.gov/>.
- [17] Modelo de Prototipos. https://es.wikipedia.org/wiki/Modelo_de_prototipos.
- [18] Trello. <https://trello.com/es>.
- [19] Slack. <https://slack.com/intl/es-es/>.
- [20] Repositorio del proyecto - TFG-Bebop-YOLO. <https://github.com/JJavier98/TFG-Bebop-YOLO>.
- [21] Carpeta MEGA con resultados de los experimentos. https://mega.nz/folder/YQpWEAiY#Xq4C890boVrrkhrA-68_AQ.
- [22] ROS Wiki. <http://wiki.ros.org/ROS/Introduction>.
- [23] Desarrollo de aplicaciones basadas en visión con entorno ROS para el dron Bebop 2 - Valero Lavid - Universidad Politécnica de Alcalá. <https://ebuah.uah.es/dspace/handle/10017/30383>.
- [24] Estructura de mensaje Image de ROS. http://docs.ros.org/melodic/api/sensor_msgs/html/msg/Image.html.
- [25] Estructura de mensaje Twist de ROS. http://docs.ros.org/melodic/api/geometry_msgs/html/msg/Twist.html.
- [26] Mani Monajjemi y Colaboradores. <http://bebop-autonomy.readthedocs.io/en/latest/contribute.html#sec-contribs>.
- [27] Bebop2. <https://www.parrot.com/es/drones/parrot-bebop-2>.
- [28] Estructura de mensaje Twist de ROS. https://es.wikipedia.org/wiki/Pilotaje_con_visión_remota.
- [29] Joseph Redmon - YOLOv3. <https://pjreddie.com/darknet/yolo/>.
- [30] Distancia de Mahalanobis. https://es.wikipedia.org/wiki/Distancia_de_Mahalanobis.
- [31] Hungarian Algorithm. https://en.wikipedia.org/wiki/Hungarian_algorithm, https://es.wikipedia.org/wiki/Algoritmo_húngaro.
- [32] VirtualBox. <https://www.virtualbox.org/>.
- [33] NVIDIA CUDA. <https://developer.nvidia.com/cuda-zone>.

- [34] CITIC. <http://citic.ugr.es/>.
- [35] Qidian213 - DeepSORT. https://github.com/Qidian213/deep_sort_yolov3.
- [36] DeepSORT videocaptureasync module. https://github.com/Qidian213/deep_sort_yolov3/issues/154.
- [37] Gaussian Blur. https://en.wikipedia.org/wiki/Gaussian_blur.
- [38] MOT Challenge. <https://motchallenge.net/>.

*